西安交通大學
XI'AN JIAOTONG UNIVERSITY

人工智能
Artificial Intelligence

- 主讲：刘欢
- 西安交通大学计算机学院
- E-mail：huanliu@xjtu.edu.cn

第六章 机器学习

- 6.5 支持向量机
  - 6.5.1 概念
  - 6.5.2 对偶问题
  - 6.5.3 核函数
  - 6.5.4 软间隔

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

分类的最基本思想：

基于训练集D，在样本空间中找到一个**划分超平面**

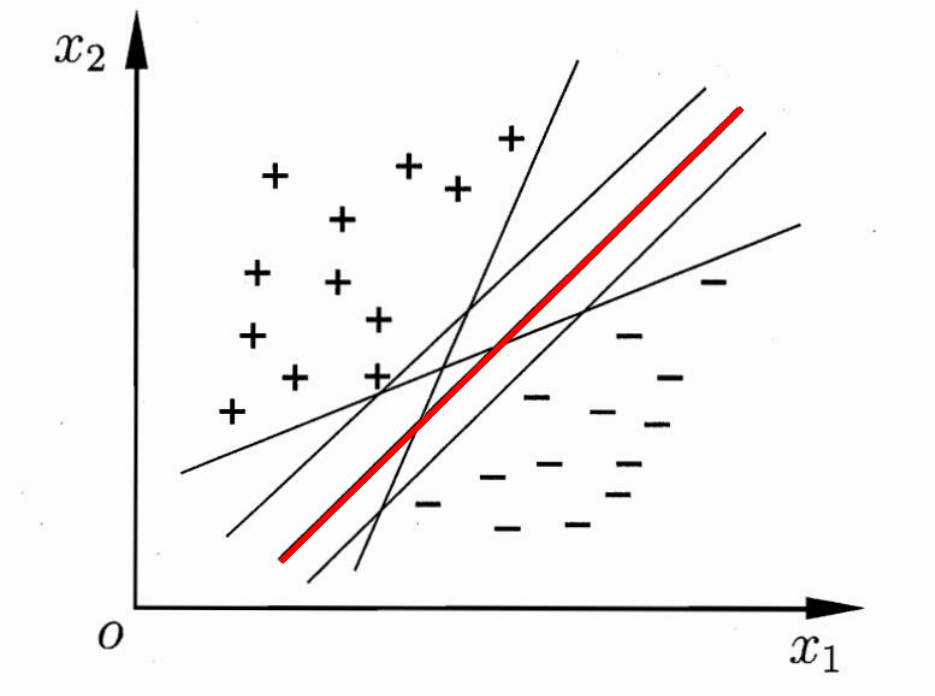

哪个超平面最好？

正中间。容忍性好，鲁棒性高，泛化能力最强。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

- 样本空间中，划分超平面可用以下线性方程描述：

$$\boldsymbol{w}^T\boldsymbol{x} + b = 0$$

其中， $\boldsymbol{w} = (\boldsymbol{w}_1; \boldsymbol{w}_2; \ldots; \boldsymbol{w}_d)$为法向量，决定超平面的方向；$b$为位移项，决定超平面与原点之间的距离。

- 样本空间中任意点$\boldsymbol{x}$到超平面$(\boldsymbol{w}, b)$的距离：

$$r = \frac{|\boldsymbol{w}^T\boldsymbol{x} + b|}{||\boldsymbol{w}||}$$

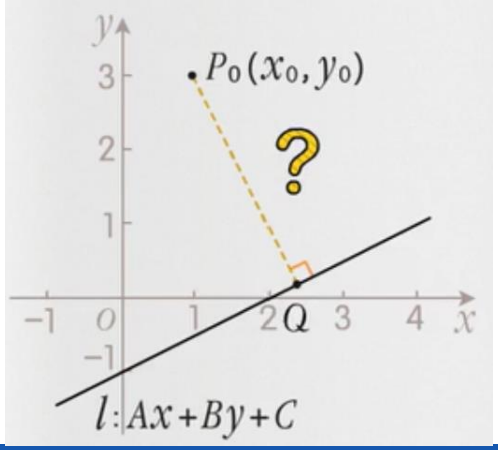

参考P_0到直线l的距离： $\dfrac{|Ax_0 + By_0 + C|}{\sqrt{A^2 + B^2}}$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

- 假设超平面$(\boldsymbol{w}, b)$能将训练样本正确分类，即对于$(\boldsymbol{x}_i, y_i) \in D$，若$y_i = +1$则$\boldsymbol{w}^T\boldsymbol{x}_i + b > 0$；若$y_i = -1$,则$\boldsymbol{w}^T\boldsymbol{x}_i + b < 0$。

泛化能力不足

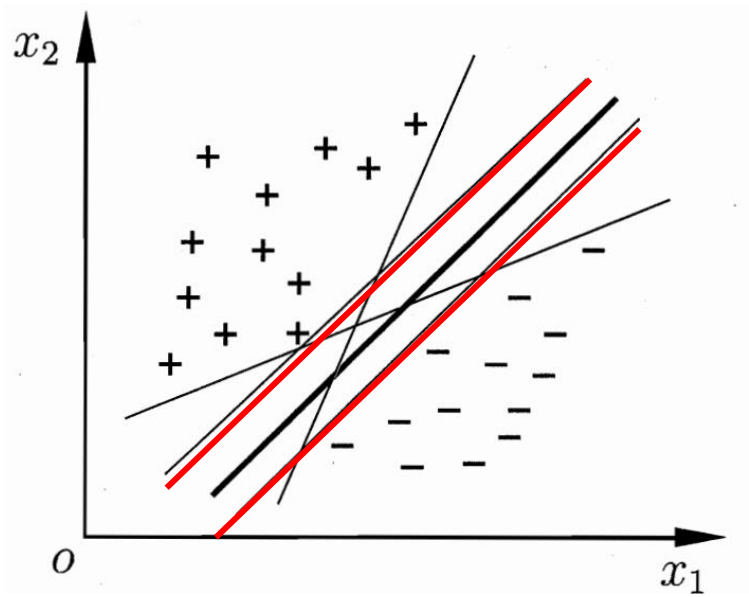

边界超平面

$$\begin{cases} \boldsymbol{w}^T\boldsymbol{x}_i + b \geq +1, y_i = +1; \\ \boldsymbol{w}^T\boldsymbol{x}_i + b \leq -1, y_i = -1. \end{cases}$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

- 距离超平面最近的几个训练样本点能够使得边界超平面等式成立$\boldsymbol{w}^T\boldsymbol{x}_i + b = \pm 1$，称为“支持向量”(support vector)
- 两个异类支持向量到超平面的距离之和称为“间隔”(margin)

$$\gamma = \frac{2}{||\boldsymbol{w}||}$$

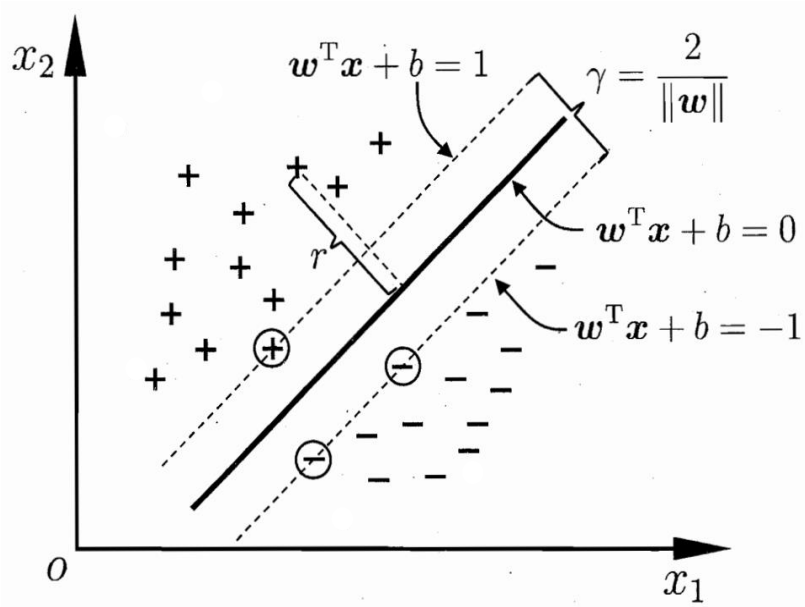

寻找具有“最大间隔”超平面：

$$\max_{\boldsymbol{w},b} \frac{2}{||\boldsymbol{w}||}$$

$$s.t.\, y_i(\boldsymbol{w}^T x_i + b) \geq 1, i = 1,2 \ldots, m$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

- 最大化间隔，即最大化$\|\boldsymbol{w}\|^{-1}$，等价于最小化$\|\boldsymbol{w}\|^2$，可得到支持向量机(Support Vector Machine)的基本型

$$\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$s.t.\ y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b) \geq 1, i = 1,2,\dots,m.$$

- 线性可分支持向量机（亦称作硬间隔支持向量机）
- 线性支持向量机（软间隔支持向量机）
- 非线性支持向量机

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.1 概念

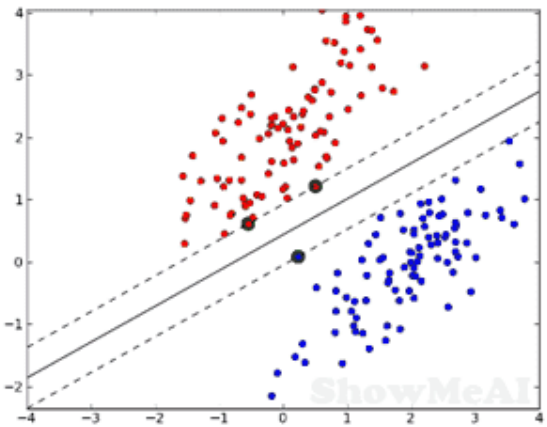

线性可分支持向量机

linear support vector machine

in linearly separable case

亦称作硬间隔支持向量机

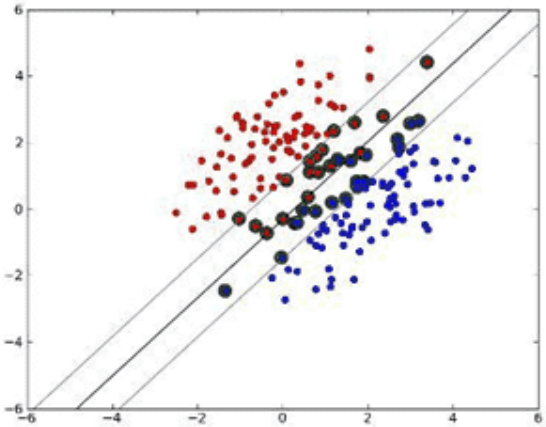

线性支持向量机

linear support vector machine

又叫软间隔支持向量机

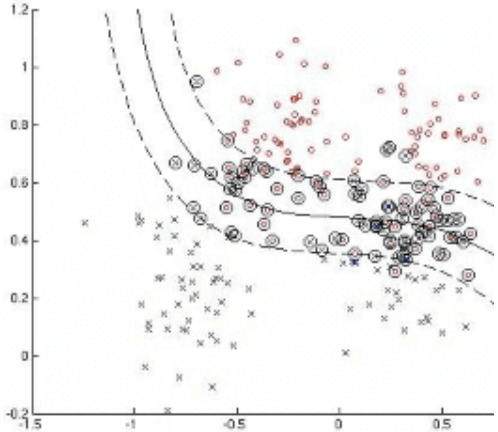

非线性支持向量机

non-linear

support vector machine

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

①给定优化问题

$$\min_{x} f(x)$$
$$s.t.\ h_i(x) \le 0, i = 1,2,\dots,m$$

②写出拉格朗日函数（无约束的原始问题）

$$L(x,\lambda) = f(x) + \sum_{i=1}^{m} \lambda_i h_i(x)$$

③写出对偶函数

$$g(\lambda) = \min_{x,\lambda} L(x,\lambda)$$

④列出对偶问题

$$\max_{\lambda} g(\lambda)$$
$$s.t.\ \ \lambda \ge 0$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

求解：

$$\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$
$$s.t.\ y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b) \geq 1, i = 1,2,\dots,m. \qquad (1)$$

可使用拉格朗日乘子法得到其“对偶问题”：

- 为公式(1)的每条约束添加拉格朗日乘子$\alpha_i \geq 0$，可得该问题的拉格朗日函数：

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 + \sum_{i=1}^{m} \alpha_i(1 - y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b)) \qquad (2)$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

- 根据拉格朗日对偶性，原始问题的对偶问题是极大极小问题：$\max_{\boldsymbol{\alpha}} \min_{\boldsymbol{w},b} L(\boldsymbol{w}, b, \boldsymbol{\alpha})$。所以，为了得到对偶问题的解，需要先求$L(\boldsymbol{w}, b, \boldsymbol{\alpha})$对$\boldsymbol{w}, b$的极小值，再求对$\boldsymbol{\alpha}$的极大值。

- 首先求 $\min_{\boldsymbol{w},b} L(\boldsymbol{w}, b, \boldsymbol{\alpha})$。令$L(\boldsymbol{w}, b, \boldsymbol{\alpha})$对$\boldsymbol{w}$和$b$的偏导为零可得：

$$\frac{\partial L}{\partial \boldsymbol{w}} = \boldsymbol{w} - \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i = 0 \qquad \boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i\,, \tag{3}$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \qquad 0 = \sum_{i=1}^{m} \alpha_i y_i \tag{4}$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

- 将式(3) $\boldsymbol{w}=\sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i$带入拉格朗日函数(2)可得：

$$
\begin{aligned}
\min_{\boldsymbol{w},b} L(\boldsymbol{w},b,\boldsymbol{\alpha}) &= \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}+\sum_{i=1}^{m}\alpha_i\big(1-y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)\big) \\
&= \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}+\sum_{i=1}^{m}\alpha_i-\sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i^T\boldsymbol{w}-\sum_{i=1}^{m}\alpha_i\, y_i b \\
&= \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}+\sum_{i=1}^{m}\alpha_i-\boldsymbol{w}^T\boldsymbol{w}-0 \\
&= \sum_{i=1}^{m}\alpha_i-\frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i y_i\,\alpha_j y_j \boldsymbol{x}_i^T\boldsymbol{x}_j
\end{aligned}
$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

- 求$\min\limits_{w,b} L(\boldsymbol{w}, b, \boldsymbol{\alpha})$对$\boldsymbol{\alpha}$的极大值，即对偶问题：

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i y_i \alpha_j y_j \boldsymbol{x}_i^T \boldsymbol{x}_j$$

$$s.t. \quad \sum_{i=1}^{m} \alpha_i y_i = 0,$$

$$\alpha_i \geq 0, i = 1,2,\dots,m.$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

- KKT(Karush-Kuhn-Tucker)条件满足时，原始问题与对偶问题的最优值相同，即可用解对偶问题代替解原始问题。
- 假设对偶问题的解为$\boldsymbol{\alpha}^*$，可得到模型：

SMO算法求解

$$f(\boldsymbol{x}) = \boldsymbol{w}^T\boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i^* y_i \boldsymbol{x}_i^T \boldsymbol{x} + b$$

KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) - 1 \geq 0 \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0 \end{cases}$$

- 对任意训练样本$(\boldsymbol{x}_i, y_i)$,总有$\alpha_i = 0$或$y_i f(\boldsymbol{x}_i) = 1$。
- 若$\alpha_i = 0$, 则不会影响$\boldsymbol{w}$；若$\alpha_i > 0$, 则必有$y_i f(\boldsymbol{x}_i) = 1$，即支持向量。

性质：SVM最终模型仅与支持向量有关。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.2 对偶问题

假设求解出了$\boldsymbol{\alpha}$, 那么根据KKT条件, 可得：

1. $\boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i$,
2. 选取一个$\alpha_i > 0$ 可得$y_i(\boldsymbol{w}^T \boldsymbol{x}_i + b) = 1 \rightarrow \boldsymbol{w}^T \boldsymbol{x}_i + b = y_i \rightarrow b = y_i - \boldsymbol{w}^T \boldsymbol{x}_i$

观察对偶支持向量机求解可以发现对偶问题的好处为：

1. 只需要优化$\boldsymbol{\alpha}$而不是b和$\boldsymbol{w}$，降低了算法的时间复杂度
2. 通过查看$a_i > 0$便可找出支持向量

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

- 假设：训练样本是线性可分的，即存在一个划分超平面能将训练样本正确分类。
- 现实：原始样本空间内可能并不存在一个能正确划分两类样本的超平面，如“异或问题”

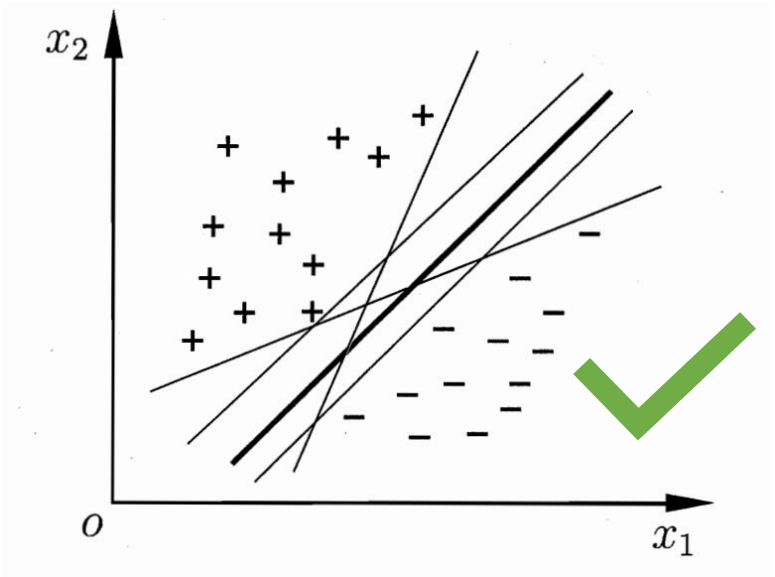

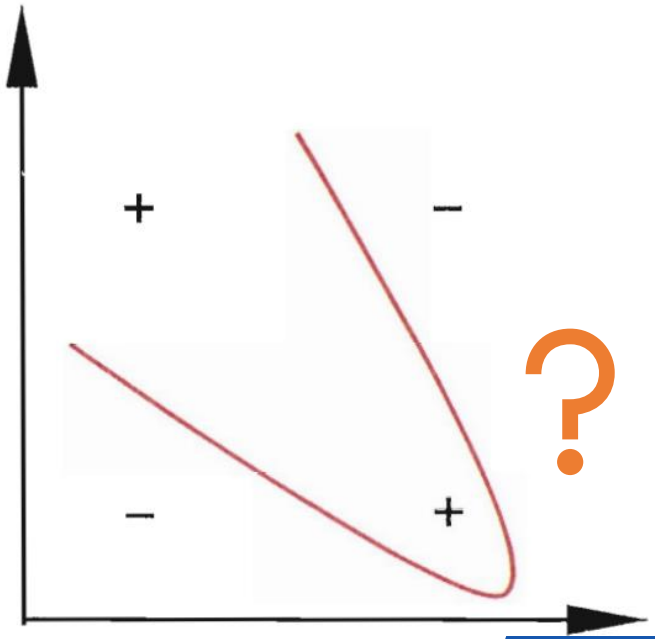

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

- 解决方案：将样本从原始空间映射到一个更高维的特征空间，使得样本在该特征空间内线性可分。
- 令$\phi(\boldsymbol{x})$表示将$\boldsymbol{x}$映射后的特征向量，则特征空间中超平面：

$$f(x) = \boldsymbol{w}^T\phi(\boldsymbol{x}) + b$$

原问题转化为：

$$\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$s.t. \quad y_i(\boldsymbol{w}^T\phi(\boldsymbol{x}_i) + b) \geq 1, i = 1,2,\dots,m$$

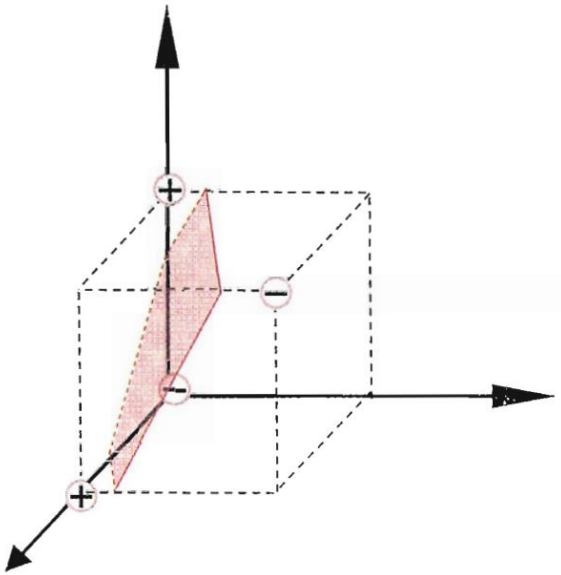

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

- 对偶问题：

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \underline{\phi(\boldsymbol{x}_i)^T \phi(\boldsymbol{x}_j)}$$

$$s.t. \sum_{i=1}^{m} \alpha_i y_i = 0,$$

$$\alpha_i \geq 0, i = 1,2, \dots, m$$

- $\phi(\boldsymbol{x}_i)^T \phi(\boldsymbol{x}_j)$：样本$\boldsymbol{x}_i$与$\boldsymbol{x}_j$映射到特征空间之后的内积
- 维度可能很高，难以直接计算。

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \langle \phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j) \rangle = \phi(\boldsymbol{x}_i)^T \phi(\boldsymbol{x}_j)$$

即特征空间内积 → $\boldsymbol{x}_i$与$\boldsymbol{x}_j$在原始样本空间中函数κ计算结果

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

- 原始对偶问题即可转化为：

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \kappa(\boldsymbol{x}_i, \boldsymbol{x}_j)$$

- 求解后即可得：

$$f(\boldsymbol{x}) = \boldsymbol{w}^T \phi(\boldsymbol{x}) + b = \sum_{i=1}^{m} \alpha_i y_i \phi(\boldsymbol{x}_i)^{\boldsymbol{T}} \phi(\boldsymbol{x}) + b$$

支持向量展式 → $= \sum_{i=1}^{m} \alpha_i y_i \kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) + b$ 核函数

如何获得核函数？

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

定理： 令$\mathcal{X}$为输入空间， $\kappa(\cdot,\cdot)$是定义在$\mathcal{X}\times\mathcal{X}$上的对称函数，则$\kappa$是核函数当且仅当对于任意数据$D=\{x_1,x_2,\ldots,x_m\}$，“核矩阵”（kernel matrix）K总是半正定的：

$$\mathbf{K}=\begin{bmatrix}\kappa(\boldsymbol{x}_1,\boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_1,\boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_1,\boldsymbol{x}_m)\\ \vdots & \ddots & \vdots & \ddots & \vdots\\ \kappa(\boldsymbol{x}_i,\boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_i,\boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_i,\boldsymbol{x}_m)\\ \vdots & \ddots & \vdots & \ddots & \vdots\\ \kappa(\boldsymbol{x}_m,\boldsymbol{x}_1) & \cdots & \kappa(\boldsymbol{x}_m,\boldsymbol{x}_j) & \cdots & \kappa(\boldsymbol{x}_m,\boldsymbol{x}_m)\end{bmatrix}$$

只要一个对称函数所对应的核矩阵半正定，

即可作为核函数使用。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.3 核函数

常用核函数：

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^\top \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^\top \boldsymbol{x}_j)^d$	$d \geq 1$为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\lVert \boldsymbol{x}_i - \boldsymbol{x}_j \rVert^2}{2\delta^2}\right)$	$\delta > 0$为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\lVert \boldsymbol{x}_i - \boldsymbol{x}_j \rVert}{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh(\beta \boldsymbol{x}_i^\top \boldsymbol{x}_j + \theta)$	tanh为双曲正切函数, $\beta > 0$, $\theta < 0$

此外，还可以通过核函数之间的组合得到新的核函数。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔 (soft margin)

- 假设：训练样本在样本空间或特征空间中是线性可分的，即存在超平面能将不同类的样本完全划开。
- 现实：难以确定合适的核函数使得训练样本在特征空间中线性可分。

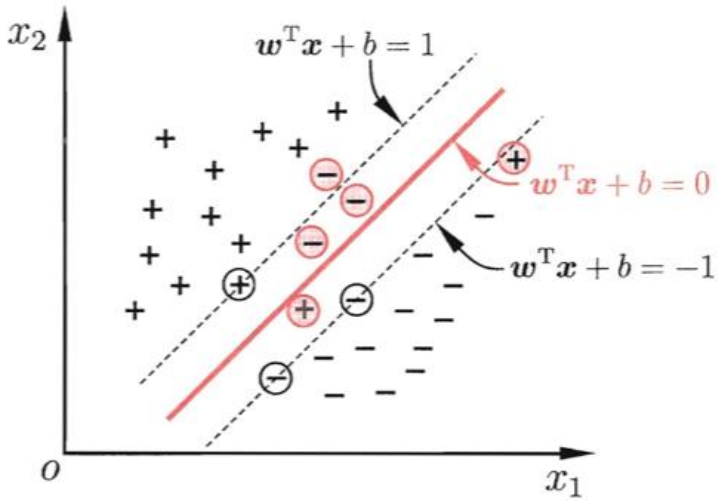

软间隔：

允许某些样本不满足约束

$$y_i(\boldsymbol{w}^T\boldsymbol{x}_i+b)\geq 1$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔

- 软间隔优化目标：

$$\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} \ell_{0/1}(y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b) - 1)$$

其中$C > 0$是一个常数， $\ell_{0/1}$是 0/1 “损失函数”

$$\ell_{0/1}(z) = \begin{cases} 1, if\ z < 0; \\ 0, otherwise. \end{cases}$$

当C为无穷大时，迫使所有样本均满足约束$y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b) \geq 1$;

当C为有限值时，允许一些样本不满足约束。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔

- $\ell_{0/1}$非凸、非连续、数学性质差，使问题不易求解。
- 采用其他函数代替$\ell_{0/1}$，称为“替代损失”

常用的替代损失函数：

hinge损失：$\ell_{hinge}(z) = \max(0,1-z)$;

指数损失：$\ell_{exp}(z) = \exp(-z)$;

对率损失：$\ell_{log}(z) = \log(1+\exp(-z))$

$$\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} \max(0,1-y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b));$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔

- 引入“松弛变量”$\xi_i \geq 0$, 可将上式重写为：

$$\min_{\boldsymbol{w},b,\xi_i} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}\xi_i$$

$$s.t.\quad y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, i = 1,2,\dots,m$$

软间隔支持向量机

理解：在线性可分问题的基础上增加惩罚函数$C\sum_{i=1}^{m}\xi_i$

调节参数C:表示对误分类点的惩罚程度

- C 很大时，分错的点少，过拟合情况严重
- C 很小时，分错的点多，模型不够准确。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔

- 类似地，利用拉格朗日乘子法得到拉格朗日函数：

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}, \boldsymbol{\xi}, \boldsymbol{\mu}) = \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}\xi_i + \sum_{i=1}^{m}\alpha_i\left(1 - \xi_i - y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b)\right) - \sum_{i=1}^{m}\mu_i\xi_i$$

$\alpha_i \geq 0, \mu_i \geq 0$是拉格朗日乘子

- 令$L(\boldsymbol{w}, b, \boldsymbol{\alpha}, \boldsymbol{\xi}, \boldsymbol{\mu})$ 对$\boldsymbol{w}, b, \xi_i$的偏导为0可得：

$$\boldsymbol{w} = \sum_{i=1}^{m}\alpha_i y_i \boldsymbol{x}_i\,,$$

$$0 = \sum_{i=1}^{m}\alpha_i y_i$$

$$C = \alpha_i + \mu_i$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.5.4 软间隔

- 带入拉格朗日函数，可得对偶问题：

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{N} \alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} \alpha_i y_i \alpha_j y_i \boldsymbol{x}_i^T \boldsymbol{x}_j$$

$$s.t. \sum_{i=1}^{m} \alpha_i y_i = 0,$$

$$0 \le \alpha_i \le C, i = 1,2,\dots,m$$

KKT条件:

$$\begin{cases} \alpha_i \ge 0, \mu_i \ge 0, \\ y_i f(\boldsymbol{x}_i) - 1 + \xi_i \ge 0, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1 + \xi_i) = 0, \\ \xi_i \ge 0, \mu_i \xi_i = 0. \end{cases}$$

软间隔支持向量机的最终模型仅与支持向量有关，仍然保持了稀疏性。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

SVM案例

- 使用SVM进行鸢尾花(Iris)分类

山鸢尾

杂色鸢尾

维吉尼亚鸢尾

属性：萼片长度、萼片宽度、花瓣长度、花瓣宽度

$$x = [6.2,3.4,5.4,2.3] \quad y = 2;$$
$$x = [5.1\ 3.5\ 1.4\ 0.2] \quad y = 0;$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

SVM案例

```python
import numpy as np
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.metrics import classification_report, accuracy_score
# 2. 加载鸢尾花数据集
iris = datasets.load_iris()
X = iris.data  # 特征数据
y = iris.target  # 标签数据
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
```

使用线性核函数
且误分类惩罚系数为1

```python
# 4. 使用 SVM 训练分类模型
svm = SVC(kernel='linear', C=1)
svm.fit(X_train, y_train)
# 5. 测试模型并评估结果
y_pred = svm.predict(X_test)
print("分类报告：")
print(classification_report(y_test, y_pred))
accuracy = accuracy_score(y_test, y_pred)
print(f"准确率：{accuracy:.4f}")
```

```
分类报告：
              precision    recall  f1-score   support

           0       1.00      1.00      1.00        19
           1       1.00      1.00      1.00        13
           2       1.00      1.00      1.00        13

    accuracy                           1.00        45
   macro avg       1.00      1.00      1.00        45
weighted avg       1.00      1.00      1.00        45

准确率：1.0000
```


西安交通大学 XI'AN JIAOTONG UNIVERSITY

- 6.6 贝叶斯分类器
  - 6.6.1 贝叶斯法则
  - 6.6.2 朴素贝叶斯方法

6.6.1 贝叶斯法则（定理、公式）

$$P(h|d) = \frac{P(d|h)P(h)}{P(d)}$$

- 先验概率$P(h)$：还没有训练数据之前，某个假设$h \in H$的初始概率。
  - 反映了背景知识，表示h是一个正确假设的可能性。
  - 若没有该信息，可简单地将每个候选假设赋予相同的先验概率
- 证据因子$P(d)$：训练数据d的先验概率，也就是在任何假设都未知或不确定时d的概率。
- 似然度$P(d|h)$：已知假设h成立时d的概率，称之为类条件概率，或者给定假设h时数据d的似然度。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.6.1 贝叶斯法则

$$P(h|d) = \frac{P(d|h)P(h)}{P(d)}$$

- 后验概率$P(h|d)$：给定数据d时假设h成立的概率。
  - 后验概率是学习的结果，反映了在看到训练数据后，假设h成立的置信度。
  - 该概率用作解决问题时的依据，即给定数据根据该概率做决策。
- 先验概率$P(h)$与训练数据无关，独立于d；后验概率$P(h|d)$与训练数据相关，反映了数据d的影响。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.6.1 贝叶斯法则

- 贝叶斯法则解决的机器学习任务一般是：

  在给定训练数据D时，确定假设空间H中的最优假设（类别）。这是典型的分类问题。

- 贝叶斯法则提供了一种计算假设概率的方法。
- 贝叶斯分类器：在给定数据d、假设空间H中不同假设的先验概率以及有关知识下的最可能假设。
- 如何使用：极大后验假设和极大似然假设

西安交通大学 XI'AN JIAOTONG UNIVERSITY

极大后验假设

极大后验假设（MAP假设）

极大后验假设$h_{MAP}(h_{MAP} \in H)$ 就是在候选假设集合H中寻找对于给定数据d使后验概率$P(h|d)$最大的那个假设。

$$h_{MAP} = argmax_{h\in \mathrm{H}} P(h|d)$$

$$= argmax_{h\in \mathrm{H}} \frac{P(d|h)P(h)}{P(d)}$$

$$= argmax_{h\in H} P(d|h)P(h)$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

极大似然假设

极大似然假设（ML假设）

极大似然假设$h_{ML}(h_{ML} \in H)$ 就是在候选假设集合H中选择使给定数据d似然度（即类条件概率）$P(d|h)$最大的假设，即ML假设$h_{ML}(h_{ML} \in H)$是满足下式的假设：

$$h_{ML} = argmax_{h \in H} P(d|h)$$

- 若所有假设的先验概率都相同，则MAP就退化成ML
- ML在没有先验知识或者先验知识不重要时使用，而MAP则在有可用的先验知识时更为合适。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

例子：医疗诊断问题

已知：

- 有两个可选的假设：病人有癌症、病人无癌症
- 观察数据来自化验结果：阳性(+)、阴性(-)
- 先验知识：所有人口中，患病率是0.008
- 对确实有病的患者的化验准确率为98%；对确实无病的患者的化验准确率为97%

$$P(cancer) = 0.008, P(\neg cancer) = 0.992,$$
$$P(+|cancer) = 0.98, P(-|cancer) = 0.02,$$
$$P(+|\neg cancer) = 0.03, P(-|\neg cancer) = 0.97$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

例子：医疗诊断问题

问题：

- 有一个新病人，化验结果为阳性(+)，该病人是否有癌症？

按照极大后验假设推断：

$$P(cancer|+) = \frac{P(+|cancer)P(cancer)}{P(+)} = \frac{0.0078}{P(+)},$$

$$P(\neg cancer|+) = \frac{P(+|\neg cancer)P(\neg cancer)}{P(+)} = \frac{0.0298}{P(+)},$$

$$P(\neg cancer|+) > P(cancer|+)$$

$$h_{MAP} = \neg cancer$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

Bayes算法的特点

优点：

- 通用性好，只要有数据就可以应用。
- 结论完全客观，不具有任何主观因素。
- 为衡量多个假设的置信度提供定量方法，可以计算每个假设的显式概率，提供客观的选择标准
- 允许假设做出不确定性的预测。

缺点：

- 要求满足较强的理论条件，特别是独立性条件。
- 分类结果很大程度上依赖于先验概率。
- 不是完全接受或拒绝假设，只是观察到数据后增大减少可能性。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.6.2 朴素贝叶斯算法

- 朴素贝叶斯算法的核心思想是通过考虑特征概率来预测分类，即对于给出的待分类样本$X\{a_1, a_2, \dots, a_n\}$，求解在此样本出现的条件下各个类别$h_i$出现的概率，哪个$P(h_i|X)$最大，就认为此待分类样本属于哪个类别。
- “朴素”（Naïve）即简单，属性互相独立。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.6.2 朴素贝叶斯算法

- 在机器学习中一个实例x往往有很多属性$< a_1, a_2, \dots, a_n >$
- 则依据MAP假设有：

$$h_{MAP} = argmax_{h_i \in H} P(h_i | a_1, a_2, \dots, a_n)$$

$$= argmax_{h_i \in H} \frac{P(a_1, a_2, \dots, a_n | h_i) P(h_i)}{P(a_1, a_2, \dots, a_n)}$$

$$= argmax_{h_i \in H} P(a_1, a_2, \dots, a_n | h_i) P(h_i)$$

问题：若要估计所有$P(a_1, a_2, \dots, a_n | h_i)$项，则必须计算$a_1, a_2, \dots, a_n$ 的所有可能取值组合，再乘以可能得目标值数据。即高维数据难以计算。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.6.2 朴素贝叶斯算法

- 朴素贝叶斯分类器采用“属性条件独立性假设”：

  对已知类别，假设所有属性相互独立，即假设每个属性独立地对分类结果发生影响。

$$P(a_1, a_2, \dots, a_n | h_i) = \prod_j P(a_j | h_i)$$

- 朴素贝叶斯分类器则为：

$$h_{NB} = argmax_{h_i \in H} P(h_i) \prod_j P(a_j | h_i)$$

西安交通大學 XI'AN JIAOTONG UNIVERSITY

6.6.2 朴素贝叶斯算法

- 朴素贝叶斯分类器的训练过程就是基于训练集D来估计类先验概率$P(h)$，并为每个属性估计条件概率$P(a_j|h_i)$
- 令D_c表示训练集D中第c类样本组成的集合，若有充足的独立同分布样本，则可估计出类先验概率：$P(c)=\frac{|D_c|}{|D|}$
- 条件概率：

  离散属性：$P(a_i|c)=\frac{|D_{c,a_i}|}{|D_c|}$ → D_{c,a_i}表示D_c中在第i个属性上取值为a_i的样本集合。

  连续属性：可考虑概率密度函数。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

例子

- 任务：根据天气、考试情况和朋友参与情况，预测学生是否会参加活动（是、否）。
- 预测：天气 = 雨天，考试 = 无考试，朋友参与 = 是

天气	考试	朋友参与	是否参加
晴天	无考试	是	是
晴天	有考试	是	否
雨天	无考试	是	是
雨天	有考试	否	否
晴天	无考试	否	是

先验概率：

$$P(\text{是}) = \frac{3}{5}, P(\text{否}) = \frac{2}{5}$$

条件概率：

$$P(\text{雨天}|\text{是}) = \frac{1}{3}, P(\text{无考试}|\text{是}) = \frac{2}{3}$$

$$P(\text{朋友}|\text{是}) = \frac{2}{3}, P(\text{雨天}|\text{否}) = \frac{1}{2}$$

$$P(\text{无考试}|\text{否}) = \frac{1}{2}, P(\text{朋友}|\text{否}) = \frac{1}{2}$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

例子

后验概率：

$$P(\text{是}|X) \propto P(\text{天气} = \text{雨天}|\text{是}) \cdot P(\text{考试} = \text{无考试}|\text{是}) \cdot$$

$$P(\text{朋友参与} = \text{是}|\text{是}) \cdot P(\text{是}) = \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{3}{5} = \frac{4}{45}$$

$$P(\text{否}|X) \propto \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{2}{5} = \frac{1}{20}$$

$$P(\text{是}|X) > P(\text{否}|X)$$

根据贝叶斯分类器计算结果，学生会参加活动。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

6.6.2 朴素贝叶斯算法

- 若某个属性值在训练集中没有与某个类同时出现过，则直接进行概率估计和判别将出现问题（如：计算出的概率为0）
- M-估计方法：解决训练数据中样本不足导致概率不准确的情况

  核心：在频率估计中引入先验知识，避免零概率问题。

$$P(x_i|C) = \frac{n_i + m \cdot P'(x_i)}{N + m}$$

n_i:特征值x_i在类别C中出现的次数。 N:类别C总样本数

m:平滑参数，用于调节先验信息的影响权重

$P'(x_i)$: 先验概率，通常是均匀分布或根据领域知识设的值

西安交通大學 XI'AN JIAOTONG UNIVERSITY

用贝叶斯方法过滤垃圾邮件

朴素贝叶斯方法的学习过程：

建立训练数据集 → 获取先验知识 → 生成概率表

1. 收集大量垃圾邮件和非垃圾邮件，建立垃圾邮件集和非垃圾邮件集。
2. 提取邮件主题和邮件内容中的有效字词w_i，统计在该训练集上的词频$TF(w_i)$，构建哈希表W_{span}，W_{valid}
3. 计算每个有效字词在垃圾邮件集（W_{span}）上出现的概率$P(w_i|C = spam)$和在非垃圾邮件集（W_{valid}）上出现的概率$P(w_i|C = valid)$

$$P(w_i \mid C) = \frac{TF(w_i)}{\sum_{w_i \in W} TF(w_i)}$$

西安交通大学 XI'AN JIAOTONG UNIVERSITY

用贝叶斯方法过滤垃圾邮件

朴素贝叶斯方法判定一封邮件的过程：

提取有效字词 → 计算后验概率 → 根据MAP假设判断

1. 对于一封邮件提取其所有有效字词$t_1, t_2, \dots, t_n$
2. 从哈希表W_{span}和W_{valid}中分别提取不同类别中上述有效字词的概率$P(t_i|C = span)$和$P(t_i|C = valid)$
3. 依据朴素贝叶斯方法计算该邮件为垃圾邮件的概率$P(C = span|t_1, t_2, \dots, t_n)$和为非垃圾邮件的概率$P(C = valid|t_1, t_2, \dots, t_n)$
4. 如果$P(C = span|t_1, t_2, \dots, t_n) > P(C = valid|t_1, t_2, \dots, t_n)$则该邮件为垃圾邮件，否则不是垃圾邮件。

西安交通大學 XI'AN JIAOTONG UNIVERSITY

朴素贝叶斯算法

特点

- 只要条件独立性得到满足，朴素贝叶斯分类等于MAP分类，否则只是近似MAP。
  - 条件独立性假设限制了朴素贝叶斯方法的适用范围。
  - 但在实际应用中，当违背该假定时，朴素贝叶斯也表现出相当的健壮性和高效性。
- 算法简单，但是一种很有效的机器学习方法。
- 没有明确搜索可能假设空间的过程。
  - 假设的形成不需要搜索，只是简单地计算训练样例中不同数据组合的出现频率。

西安交通大学 XI'AN JIAOTONG UNIVERSITY

完

读书报告

- 从下列主题中，选择感兴趣的一个主题，进行调研。阅读至少3篇2025年的顶会论文（如CCF A），形成调研报告。

- 多模态大模型
- 智能体
- 大模型推理
- 可解释人工智能
- AI for Science
- 脑机接口

◆报告内容需包括但不限于：

- 1. 引言（研究背景与意义、研究目的与内容）
- 2. 主题概述（关键术语定义、技术发展脉络）
- 2. 文献综述（梳理阅读的论文，并进行对比分析）
- 3. 总结与展望（现状总结、未来研究方向）
- 5. 结论
- 参考文献

◆截止日期：2025年12月21日

◆提交格式：PDF

◆2216123296@stu.xjtu.edu.cn

◆文件名：姓名_班级_学号

西安交通大學 XI'AN JIAOTONG UNIVERSITY

上机实验

编号	实验名称	实验内容
1	状态空间搜索算法编程实现	编程实现盲目搜索和启发式搜索算法，解决货郎担问题（TSP）、重排九宫等问题。
2	神经网络分类器编程实现	编程实现人工神经网络中的反向传播算法（BP算法），解决实际分类问题。

时间：2025年12月21日第15周周日晚上6-10点

地点：西一楼大机房

实验报告：2025年12月28日前提交

西安交通大学 XI'AN JIAOTONG UNIVERSITY