西安交通大學
XI'AN JIAOTONG UNIVERSITY

# 数据挖掘
# 第三章：关联规则挖掘

范 铭

智能网络与网络安全教育部重点实验室
西安交通大学网络空间安全学院

1 关联规则挖掘的基本概念

2 由事务数据库挖掘单维布尔关联规则

3 多层关联规则挖掘

4 多维关联规则挖掘

5 关联规则、相关性、因果关系的区别

基本要求：掌握关联规则、多层关联规则、多维关联规则的基本概念，掌握各种关联规则挖掘的算法

# 本章内容

3.1 关联规则挖掘的基本概念

3.2 由事务数据库挖掘单维布尔关联规则

3.3 多层关联规则挖掘

3.4 多维关联规则挖掘

3.5 关联规则、相关性、因果关系的区别

# 3.1 基本概念

- 关联规则挖掘：从事务数据库中发现项集之间有趣的关联.
- 应用： 购物篮分析（Basket data analysis）、交叉营销（cross-marketing）、产品目录设计（catalog design）等
- 例子：
  - 规则形式: "Body → Head [support, confidence]".
  - buys(x, "diapers") → buys(x, "beers") [0.5%, 60%]
  - major(x, "CS") ^ takes(x, "DB") → grade(x, "A") [1%, 75%]

# 3.1 基本概念

- 布尔型与数值型关联规则（基于要处理的数据类型）
  - buys(x, “SQLServer”) ^ buys(x, “DMBook”) → buys(x, “DBMiner”) [0.2%, 60%]
  - age(x, “30..39”) ^ income(x, “42..48K”) → buys(x, “PC”) [1 %, 75%]
- 单维与多维关联规则
- 单层与多层关联规则
  - What brands of beers are associated with what brands of diapers?

# 3.1 基本概念

## ■ 规则度量：支持度和置信度

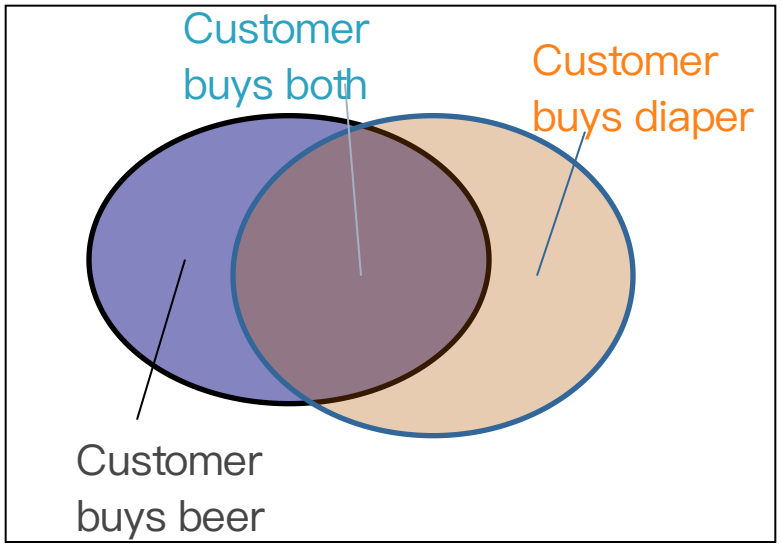


| TID | Item |
|---|---|
| 2000 | A,B,C |
| 1000 | A,C |
| 4000 | A,D |
| 5000 | B,E,F |

- 支持度s 是指事务集 D 中包含 $A \cup B$ 的百分比
  - Support $(A \rightarrow B) = P(A \cup B)$
- 置信度 c 是指D 中包含A 的事务同时也包含B的百分比
  - Confidence$(A \rightarrow B) = P(B \mid A)$

    $= P(A \cup B)/P(A)$

$A \rightarrow C$ ?　　$C \rightarrow A$ ?

# 3.1 基本概念

## ■ 规则度量：支持度和置信度

Shirt → Tie (support = 13.5% and confidence = 70%).

**Confidence**

When a customer buys a shirt, in **70%** of cases, he or she will also buy a tie!
We find this happens in **13.5%** of all purchases.

**Support**

- 设最小支持度阈值为50%，最小置信度阈值为50%
  - A → C (50%, 66.6%)
  - C → A (50%, 100%)
- 同时满足最小支持度阈值和最小置信度阈值的规则称作**强规则**

# 3.1 基本概念

## ■ 关联规则的形式化表示

- Let $I = \{i_1, i_2, \ldots, i_m\}$ be a set of items. Let $D$ be a set of transactions, where each transaction $T$ is a set of items such that $T \subseteq I$.
- A transaction $T$ contains $X$, a set of some items in $I$, if $X \subseteq T$.
- An association rule is an implication of the form $X \Rightarrow Y$, where $X \subset I$, $Y \subset I$, and $X \cap Y = \emptyset$.
- $X \Rightarrow Y$ holds in the transaction set $D$ with *confidence* c if c% of transactions in $D$ that contain $X$ also contain $Y$.
- $X \Rightarrow Y$ has *support* s% in the transaction set $D$ if s% of transactions in $D$ contain $X \cup Y$.

# 3.1 基本概念

- 事务数据：商场购物数据
  - Market basket transactions:

    t1 : {bread, cheese, milk}

    t2: {apple, eggs, salt, yogurt}

    … …

    tn: {biscuit, eggs, milk}
  - Concepts:

    An *item*: an item/article in a basket

    *I*: the set of all items sold in the store

    A *transaction*: items purchased in a basket; it may have TID (transaction ID)

    A *transactional dataset*: A set of transactions

# 3.1 基本概念

- 事务数据：文档数据集
  - ✓ 每个文档都可以看作一个词袋（bag of words）

    doc1： Student, Teach, School

    doc2: Student, School

    doc3: Teach, School, City, Game

    doc4: Baseball, Basketball

    doc5: Basketball, Player, Spectator

    doc6: Baseball, Coach, Game, Team

    doc7: Basketball, Team, City, Game

# 本章内容

3.1 关联规则挖掘的基本概念

3.2 由事务数据库挖掘单维布尔关联规则

3.3 多层关联规则挖掘

3.4 多维关联规则挖掘

3.5 关联规则、相关性、因果关系的区别

# 3.2 由事务数据库挖掘布尔关联规则

- 关联规则挖掘的原始算法：枚举每个可能的规则，计算其支持度与置信度。
  - 包含*d*个项目的数据集中可能的规则数目为

$$R = 3^d - 2^{d+1} + 1$$

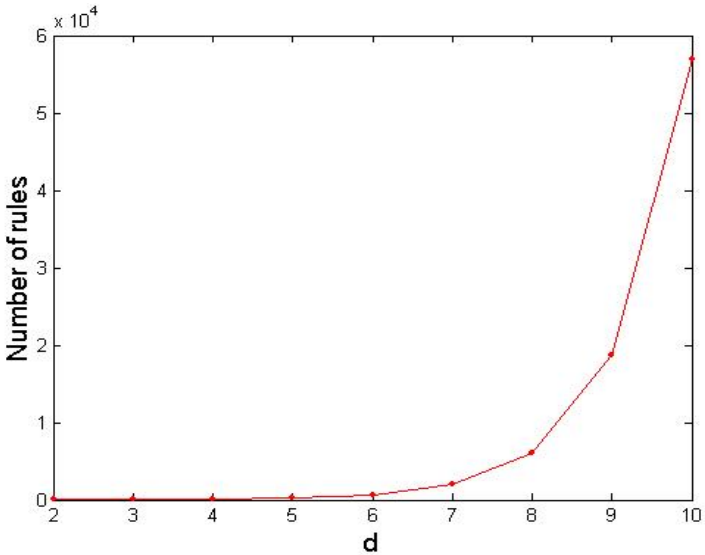


$$R = \sum_{k=1}^{d-1}\left[\binom{d}{k} \times \sum_{j=1}^{d-k}\binom{d-k}{j}\right]$$

$$= 3^d - 2^{d+1} + 1$$

If d=6, R = 602 rules

# 3.2 由事务数据库挖掘布尔关联规则

## 频繁项集性质

- 向下封闭性质（Downward closure）：频繁项集的任意子集都是频繁的
  - 如果 {beer, diaper, nuts} 是频繁的, 则 {beer, diaper}也是频繁的
  - 任何含有 {beer, diaper, nuts} 的事务数据也包含 {beer, diaper}
- Apriori 修剪原理：非频繁项集的任意超集都是非频繁的，无需生成与测试

# 3.2 由事务数据库挖掘布尔关联规则

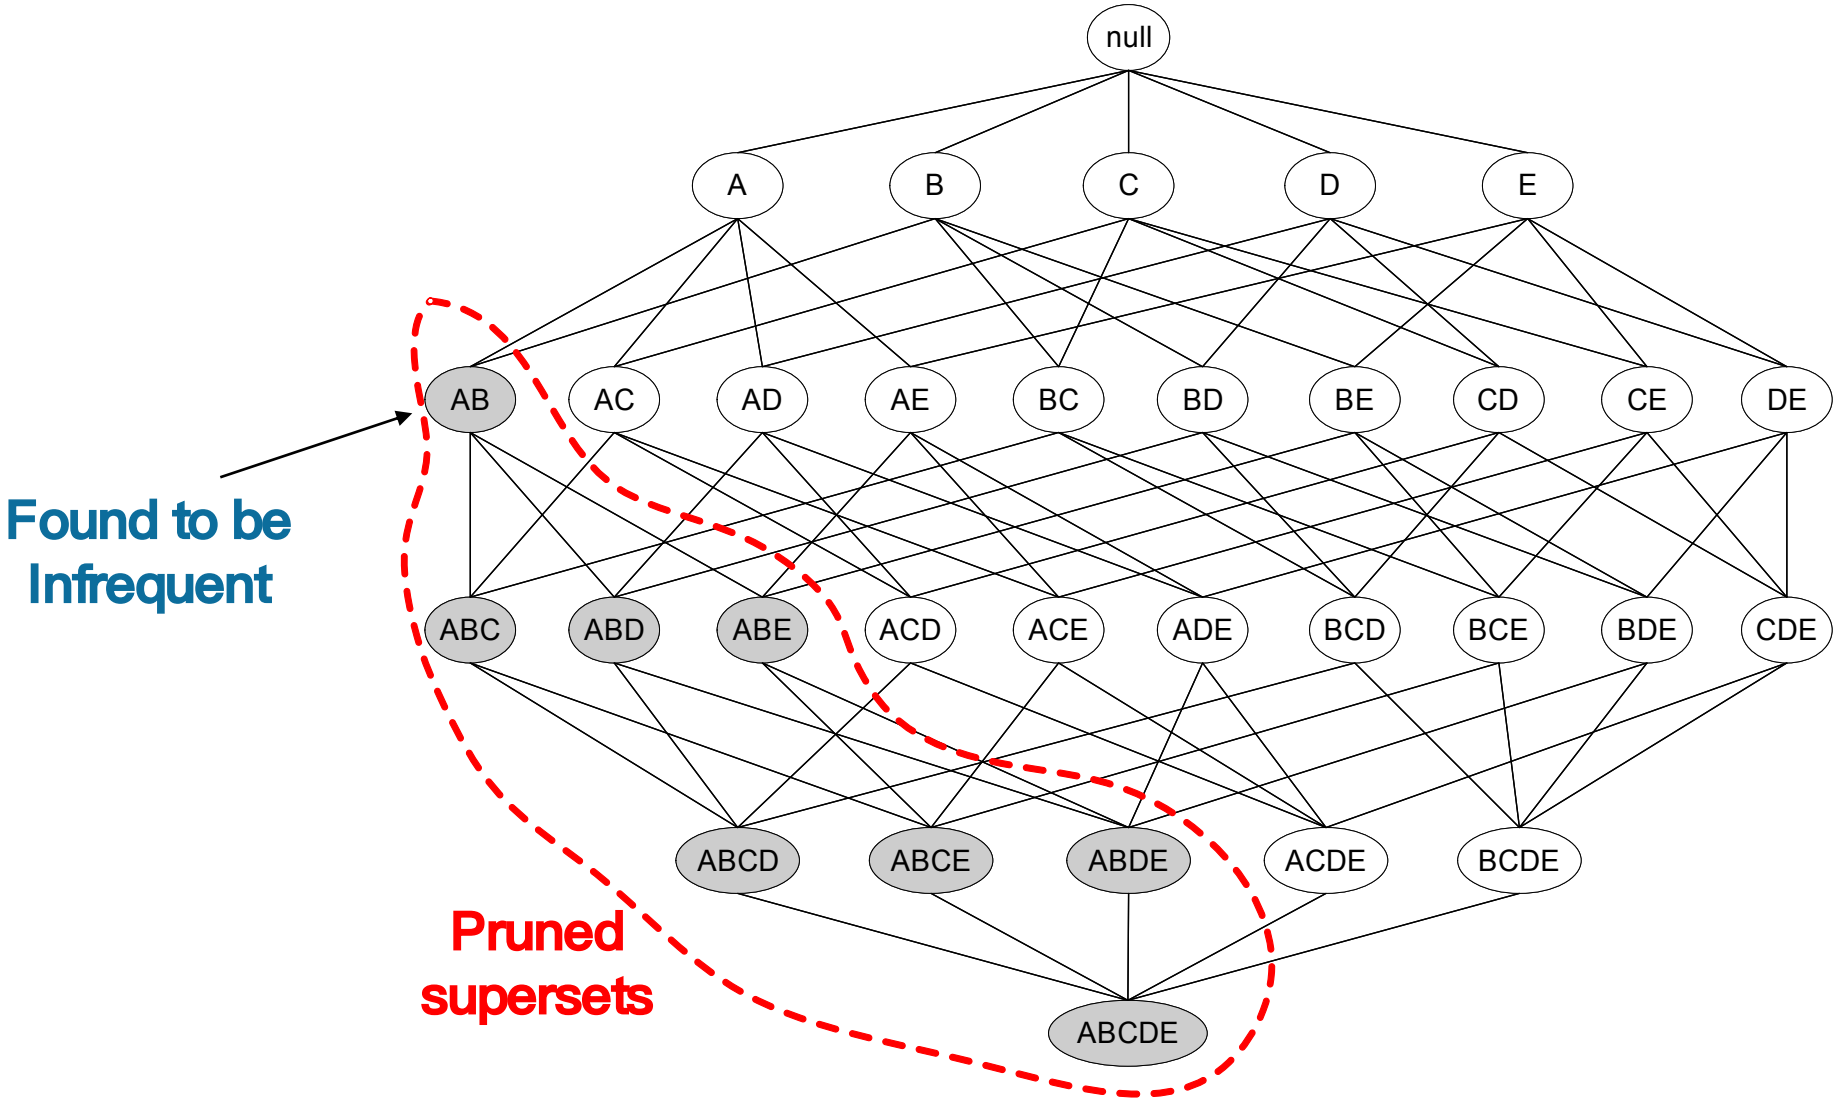

# 3.2 由事务数据库挖掘布尔关联规则

- A long pattern contains a combinatorial number of sub-patterns, e.g., $\{a_1, \ldots, a_{100}\}$ contains $\binom{100}{1} + \binom{100}{2} + \ldots + \binom{100}{100} = 2^{100} - 1 = 1.27 * 10^{30}$ sub-patterns!
- Solution: *Mine closed patterns and max-patterns instead*
- An itemset X is closed if X is *frequent* and there exists *no super-pattern* $Y \supset X$, *with the same support* as X
- An itemset X is a max-pattern if X is frequent and there exists no frequent super-pattern $Y \supset X$
- Closed pattern is a lossless compression of freq. patterns

# 3.2 由事务数据库挖掘布尔关联规则

### 1. 闭频繁项集

**定义**：

一个频繁项集被称为 **闭的**，如果它的支持度大于其**任何**直接超集的支持度。

**通俗理解**：

闭项集是一个“**代表**”。它代表了所有和它拥有**完全相同支持度**的子集。也就是说，你找不到任何一个能添加到这个项集中而不改变其支持度的物品。

**为什么重要?**：

闭项集是**无损压缩**。虽然它大大减少了需要生成的项集数量（可能比所有频繁项集少几个数量级），但你仍然能准确地知道**每个项集的支持度是多少**。

**例子**：

假设我们有交易数据，并且最小支持度是2。

- 交易1: {牛奶，面包，黄油}
- 交易2: {牛奶，面包}
- 交易3: {牛奶，黄油}
- 交易4: {面包，啤酒}

# 3.2 由事务数据库挖掘布尔关联规则

- `{面包}`：支持度 = 3 (出现在交易1,2,4)
- `{牛奶}`：支持度 = 3 (出现在交易1,2,3)
- `{面包，牛奶}`：支持度 = 2 (出现在交易1,2)
- `{面包，黄油}`：支持度 = 1 (只出现在交易1，**不频繁**)
- `{牛奶，黄油}`：支持度 = 2 (出现在交易1,3)
- `{面包，牛奶，黄油}`：支持度 = 1 (只出现在交易1，**不频繁**)

判断项集：

- `{面包}`：它的超集有 `{面包,牛奶}` (支持度2) 和 `{面包,黄油}` (支持度1)。这两个超集的支持度都**小于**3。所以 `{面包}` 是**闭频繁项集**。
- `{牛奶}`：同样，它的超集 `{牛奶,面包}` (支持度2) 和 `{牛奶,黄油}` (支持度2) 的支持度都小于3。所以 `{牛奶}` 也是**闭频繁项集**。
- `{面包，牛奶}`：它的超集是 `{面包,牛奶,黄油}`，但该超集的支持度(1) **小于**它的支持度(2)。所以 `{面包，牛奶}` 也是**闭频繁项集**。
- `{牛奶，黄油}`：它的超集 `{面包,牛奶,黄油}` 的支持度(1) **小于**它的支持度(2)。所以 `{牛奶，黄油}` 也是**闭频繁项集**。

**所有闭频繁项集为**：`{面包}`，`{牛奶}`，`{面包，牛奶}`，`{牛奶，黄油}`。

# 3.2 由事务数据库挖掘布尔关联规则

## 2. 最大频繁项集

**定义**：

一个频繁项集被称为 **最大的**，如果它的**所有**直接超集都是**非频繁**的。

**通俗理解**：

最大项集是一个“**边界**”。它是能找到的**最大的**（包含物品最多的）频繁项集。你再往里面加任何一样东西，它就不再是频繁的了。

**为什么重要？**：

最大项集是**有损压缩**。它代表了频繁项集的边界，能极其有效地减少项集数量（比闭项集还要少）。**但是，你失去了计算确切支持度的能力**。你只知道所有它的子集都是频繁的，但不知道具体每个子集的支持度是多少。

# 3.2 由事务数据库挖掘布尔关联规则

**例子**（使用同上数据）：
让我们找出最大项集。

- `{面包，牛奶，黄油}`： 是非频繁的（支持度1），所以不考虑。
- `{面包，牛奶}`： 它的超集 `{面包,牛奶,黄油}` 是非频繁的。所以 `{面包，牛奶}` 是最大频繁项集吗？**还不是**，因为我们需要检查是否还有其他更大的频繁项集。
- `{牛奶，黄油}`： 它的超集 `{面包,牛奶,黄油}` 也是非频繁的。
- `{面包}`、`{牛奶}`、`{黄油}`： 它们都有频繁的超集（例如 `{面包}` 有超集 `{面包,牛奶}`），所以它们自己不是最大的。

在这个简单的例子中，我们有两个项集： `{面包，牛奶}` 和 `{牛奶，黄油}`。它们的所有超集都是非频繁的，所以它们都是**最大频繁项集**。

**所有最大频繁项集为**： `{面包，牛奶}`，`{牛奶，黄油}`。

知道了最大项集，我们可以推断出所有它们的子集（如 `{面包}`，`{牛奶}`，`{黄油}`，`{面包,牛奶}`，`{牛奶,黄油}`）都是频繁的，但我们无法知道 `{面包}` 的支持度是3，而 `{牛奶,黄油}` 的支持度是2。我们只知道它们都超过了最小支持度阈值。

# 3.2 由事务数据库挖掘布尔关联规则

- Closed Patterns and Max-Patterns
  - a maximal itemset is a closed itemset but a closed itemset is not necessarily a maximal itemset.

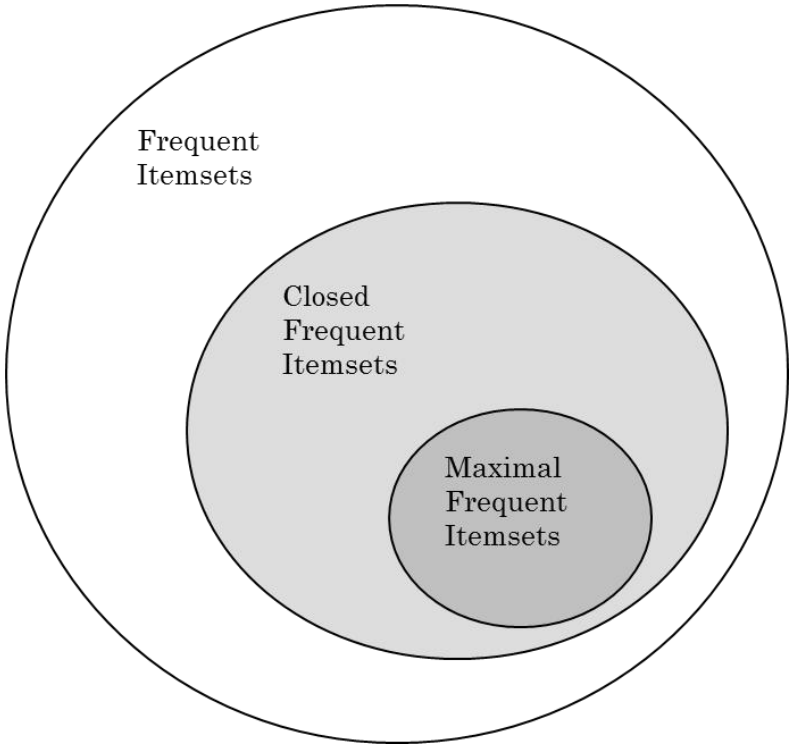

# 3.2 由事务数据库挖掘布尔关联规则

- Apriori算法
  - $C_k$: 候选 k-项集

    $L_k$: 频繁k-项集
  - Join 阶段: $C_k$ 由$L_{k-1}$链接而成
  - Prune阶段: 任何包含非频繁的(k-1)-项集都不可能是频繁的k-项集

# 3.2 由事务数据库挖掘布尔关联规则

## Apriori算法

```
L1 = {large 1-itemsets};
for ( k = 2; Lk-1 ≠ Ø; k++ ) do begin
    Ck = apriori-gen(Lk-1);    // New candidates
    forall transactions t ∈ D do begin
        Ct = subset(Ck, t);    //Candidates contained in t
        forall candidates c ∈ Ct do
            c.count++;
    end
    Lk = {c ∈ Ck | c.count ≥ minsup}
end
Answer = ∪k Lk;
```

# 3.2 由事务数据库挖掘布尔关联规则

## Apriori候选集生成

- apriori-gen 函数以所有的 $(k-1)$ 项集的集合 $L_{k-1}$ 为输入，返回所有 $k$-项集的集合 $C_k$.
- 首先, 在 join 阶段:

  insert into $C_k$

  select $p.\text{item}_1$, $p.\text{item}_2$, …, $p.\text{item}_{k-1}$, $q.\text{item}_{k-1}$

  from $L_{k-1}$ $p$, $L_{k-1}$ $q$

  where $p.\text{item}_1 = q.\text{item}_1$, …, $p.\text{item}_{k-2} = q.\text{item}_{k-2}$, $p.\text{item}_{k-1} < q.\text{item}_{k-1}$
- 其次, 在 prune 阶段, 删除所有的满足 $(k-1)$ 子集不在 $L_{k-1}$ 的项集 $c \in C_k$:

```
forall itemsets c ∈ C_k do
    forall (k−1)-subsets s of c do
        if (s ∉ L_{k−1}) then
            delete c from C_k;
```

# 3.2 由事务数据库挖掘布尔关联规则

- $L_3$={*abc, abd, acd, ace, bcd*}
- **Self-joining:** $L_3 * L_3$
  - *abcd* from *abc* and *abd*
  - *acde* from *acd* and *ace*
- **Pruning:**
  - *acde* is removed because *ade* is not in $L_3$
- $C_4$={*abcd*}

# 3.2 由事务数据库挖掘布尔关联规则

## Apriori算法举例

Database D

| TID | Items |
|---|---|
| 100 | 1 3 4 |
| 200 | 2 3 5 |
| 300 | 1 2 3 5 |
| 400 | 2 5 |

Scan D →

$C_1$

| itemset | sup. |
|---|---|
| {1} | 2 |
| {2} | 3 |
| {3} | 3 |
| {4} | 1 |
| {5} | 3 |

→ $L_1$

| itemset | sup. |
|---|---|
| {1} | 2 |
| {2} | 3 |
| {3} | 3 |
| {5} | 3 |

$C_2$

| itemset |
|---|
| {1 2} |
| {1 3} |
| {1 5} |
| {2 3} |
| {2 5} |
| {3 5} |

Scan D →

$C_2$

| itemset | sup |
|---|---|
| {1 2} | 1 |
| {1 3} | 2 |
| {1 5} | 1 |
| {2 3} | 2 |
| {2 5} | 3 |
| {3 5} | 2 |

→ $L_2$

| itemset | sup |
|---|---|
| {1 3} | 2 |
| {2 3} | 2 |
| {2 5} | 3 |
| {3 5} | 2 |

$C_3$

| itemset |
|---|
| {2 3 5} |

Scan D →

$L_3$

| itemset | sup |
|---|---|
| {2 3 5} | 2 |

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 由频繁项集产生关联规则

✓ 同时满足最小支持度和最小置信度的才是强关联规则，从频繁项集产生的规则都满足支持度要求，而其置信度则可由以下公式计算：

•Confidence(A → B)= P(B | A)=P(A∪ B)/P(A)

✓ 每个关联规则可由如下过程产生：

- 对于每个频繁项集l，产生l的所有非空子集；
- 对于每个非空子集s，如果 $\frac{\sup port_count(l)}{\sup port_count(s)} \geq \min_conf$

  则输出规则“ $s \Rightarrow (l-s)$ ”

有多少个候选规则？

# 3.2 由事务数据库挖掘布尔关联规则

- 如果{A,B,C,D} 频繁项集，候选规则为:

| | | | |
|---|---|---|---|
| ABC →D, | ABD →C, | ACD →B, | BCD →A, |
| A →BCD, | B →ACD, | C →ABD, | D →ABC |
| AB →CD, | AC → BD, | AD → BC, | BC →AD, |
| BD →AC, | CD →AB | | |

- 如果|L| = k, 那么有$2^k - 2$候选规则 (忽略L → ∅ and ∅ → L)
- 候选规则天生满足最小支持度，关键是需要判断是否满足最小置信度

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 如何有效地从频繁项集生成关联规则

➢ 一般来说，置信度不具有反单调性

c(ABC →D) can be larger or smaller than c(AB →D)

**为什么置信度不具有反单调性?**

置信度是关联规则 $A \to B$ 的度量，定义为：

$$\text{confidence}(A \to B) = \frac{\text{support}(A \cup B)}{\text{support}(A)}$$

置信度依赖于两个因素：前件 $A$ 的支持度和项集 $A \cup B$ 的支持度。当规则的前件或后件扩展时（例如，从 $A \to B$ 变为 $A \cup C \to B$），置信度可能增加、减少或保持不变，因为没有固定的趋势。这是因为：

- 扩展前件可能会减少 $\text{support}(A)$ 的速度比减少 $\text{support}(A \cup B)$ 的速度更快，导致置信度升高。
- 或者，扩展前件可能会减少 $\text{support}(A \cup B)$ 的速度更快，导致置信度降低。

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 如何有效地从频繁项集生成关联规则

- 一般来说，置信度不具有反单调性

  c(ABC →D) can be larger or smaller than c(AB →D)

- 有相同项集生成的规则的置信度具有反单调性

如果规则 $X \rightarrow Y-X$ 不满足置信度阈值，则形如 $X' \rightarrow Y-X'$ 的规则一定也不满足置信度阈值，其中 $X'$ 是 $X$ 的子集。

e.g., L = {A,B,C,D}:

为什么？

$$c(ABC \rightarrow D) \geq c(AB \rightarrow CD) \geq c(A \rightarrow BCD)$$

# 3.2 由事务数据库挖掘布尔关联规则

- 对于频繁k-项集 (k > 2)
  - 计算规则头中只有一个项的规则的置信度
  - 利用这些规则，迭代方法增加规则头中项集大小，计算置信度
  - 如果置信度小于阈值，则裁剪

{Bread, Milk, Diaper}

1-item rules

{Bread, Milk} → {Diaper}

{Milk, Diaper} → {Bread}

{Diaper, Bread} → {Milk}

2-item rules

{Bread} → {Milk, Diaper}

{Diaper} → {Milk, Bread}

{Milk} → {Diaper, Bread}

# 3.2 由事务数据库挖掘布尔关联规则

例子(Association Rule.ipynb)

# 3.2 由事务数据库挖掘布尔关联规则

Min_sup 40% (2/5)

| TID | List of Items |
|---|---|
| 1 | Beer,Diaper,Baby Powder,Bread,Umbrella |
| 2 | Diaper,Baby Powder |
| 3 | Beer,Diaper,Milk |
| 4 | Beer,Diaper,Detergent |
| 5 | Beer,Milk,Coca-Cola |

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 例子

C1 → L1

| Item | Support |
|---|---|
| Beer | "4/5" |
| Diaper | "4/5" |
| Baby Powder | "2/5" |
| Bread | "1 /5" |
| Umbrella | "1 /5" |
| Milk | "2/5" |
| Detergent | "1 /5" |
| Coca-Cola | "1 /5" |

| Item | Support |
|---|---|
| Beer | "4/5" |
| Diaper | "4/5" |
| Baby Powder | "2/5" |
| Milk | "2/5" |

# 3.2 由事务数据库挖掘布尔关联规则

- 例子

C2 → L2

| Item | Support |
|---|---|
| Beer, Diaper | |
| Beer, Baby Powder | |
| Beer, Milk | |
| Diaper,Baby Powder | |
| Diaper,Milk | |
| Baby Powder,Milk | |

| Item | Support |
|---|---|
| Beer, Diaper | "3/5" |
| Beer, Milk | "2/5" |
| Diaper,Baby Powder | "2/5" |

# 3.2 由事务数据库挖掘布尔关联规则

- 例子

C3 → empty

| Item | Support |
| --- | --- |
| Beer, Diaper,Baby Powder | |
| Beer, Diaper,Milk | |

# 3.2 由事务数据库挖掘布尔关联规则

- 例子

min_sup=40%　min_conf=70%

| Item | Support(A,B) | Suport A | Confidence |
|---|---|---|---|
| Beer, Diaper | | | |
| Beer, Milk | | | |
| Diaper,Baby Powder | | | |
| Diaper,Beer | | | |
| Milk,Beer | | | |
| Baby Powder, Diaper | | | |

# 3.2 由事务数据库挖掘布尔关联规则

- 例子

$$Beer \Rightarrow Diaper$$

support 60%, confidence 75%

$$Diaper \Rightarrow Beer$$

support 60%, confidence 75%

$$Milk \Rightarrow Beer$$

support 40%, confidence 100%

$$Baby_Powder \Rightarrow Diaper$$

support 40%, confidence 100%

# 3.2 由事务数据库挖掘布尔关联规则

- Apriori算法通常是可行的（三个因素：单调性、稀疏性、支持度）
- 提高Apriori算法的有效性

➢ Apriori算法主要的挑战

- 要对数据进行多次扫描；
- 会产生大量的候选项集；
- 对候选项集的支持度计算非常繁琐；

Assume the total number of items be 100.

| Cardinality of Itemsets | Number of Itemsets |
|---|---|
| 1 | 100 |
| 2 | 4,950 |
| 3 | 161,700 |
| 4 | 3,921,225 |
| 5 | 75,287,529 |
| 6 | 1,192,052,400 |
| 7 | 16,007,560,800 |
| 8 | 186,087,894,300 |

If a typical supermarket has at least 1,0000 different items, there are almost 50,000,000 possible 2-itemsets (i.e., itemset with the cardinality of 2) and over 1,000,000,000 possible 3-itemsets.

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 提高Apriori算法的有效性

➢ 解决思路

- 减少对数据的扫描次数；
- 缩小产生的候选项集；
- 改进对候选项集的支持度计算方法

# 3.2 由事务数据库挖掘布尔关联规则

## ■ AprioriTid算法

1. 同Apriori 算法一样利用Apriori-gen 过程生成候选项集；
2. 与Apriori算法的重要区别是支持度的确定：仅用扫描一次数据库
3. 用集合C’k 代替数据库
4. 每个C’k的元素形如<TID, $\{X_k\}$ >， 每个$X_k$ 是事务 TID包含的k项集
5. C’1 对应于数据库 D.

Database

| Items | TID |
|---|---|
| 1 3 4 | 100 |
| 2 3 5 | 200 |
| 1 2 3 5 | 300 |
| 2 5 | 400 |

C^$_1$

| Set-of-itemsets | TID |
|---|---|
| { {1},{3},{4} } | 100 |
| { {2},{3},{5} } | 200 |
| { {1},{2},{3},{5} } | 300 |
| { {2},{5} } | 400 |

$L_1$

| Support | Itemset |
|---|---|
| 2 | {1} |
| 3 | {2} |
| 3 | {3} |
| 3 | {5} |

$C_2$

| itemset |
|---|
| {1 2} |
| {1 3} |
| {1 5} |
| {2 3} |
| {2 5} |
| {3 5} |

C^$_2$

| Set-of-itemsets | TID |
|---|---|
| { {1 3} } | 100 |
| { {2 3},{2 5} {3 5} } | 200 |
| { {1 2},{1 3},{1 5}, {2 3}, {2 5}, {3 5} } | 300 |
| { {2 5} } | 400 |

$L_2$

| Support | Itemset |
|---|---|
| 2 | {1 3} |
| 3 | {2 3} |
| 3 | {2 5} |
| 2 | {3 5} |

$C_3$

| itemset |
|---|
| {2 3 5} |

C^$_3$

| Set-of-itemsets | TID |
|---|---|
| { {2 3 5} } | 200 |
| { {2 3 5} } | 300 |

$L_3$

| Support | Itemset |
|---|---|
| 2 | {2 3 5} |

# 3.2 由事务数据库挖掘布尔关联规则

- Apriori算法
  - 计算项集的支持度需要花费大量时间，需要检查数据库中的每个事务，涉及大量I/O资源
- AprioriTid算法
  - 初始阶段候选项集较大.时间开销和 Apriori 相当，并且要占用大量的内存开销

# 3.2 由事务数据库挖掘布尔关联规则

## ■ Apriori Hybrid算法

- ✓ 初始阶段: Apriori 性能较好
- ✓ 后续阶段: AprioriTid性能较好
- ✓ Apriori Hybrid:
  - 在初始阶段使用Apriori算法，后续使用AprioriTid算法
  - 缺点: Apriori 向AprioriTid过度会带来额外开销

# 3.2 由事务数据库挖掘布尔关联规则

## ■ 关联规则的兴趣度度量

- 客观度量: 支持度、置信度
- 主观度量： 最终，只有用户才能确定一个规则是否有趣的，而且这种判断是主观的，因不同的用户而异；通常认为一个规则（模式）是有趣的，如果:
  - 它是出人意料的
  - 可行动的（用户可以使用该规则做某些事情）

# 3.2 由事务数据库挖掘布尔关联规则

- 关联规则可视化
  - 表格

| Antecedent | | Consequent | Support | Confidence |
|---|---|---|---|---|
| PC，Monitor | ⇨ | Printer | 90% | 85% |
| PC | ⇨ | Printer，Monitor | 90% | 75% |
| Printer，Monitor | ⇨ | PC | 80% | 70% |

# 3.2 由事务数据库挖掘布尔关联规则

- 关联规则可视化
  - 有向图

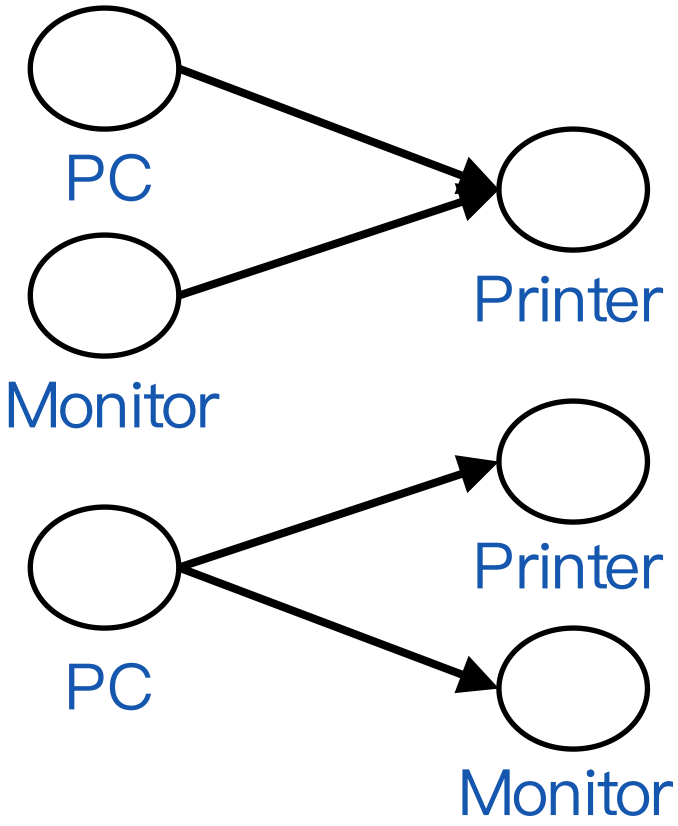


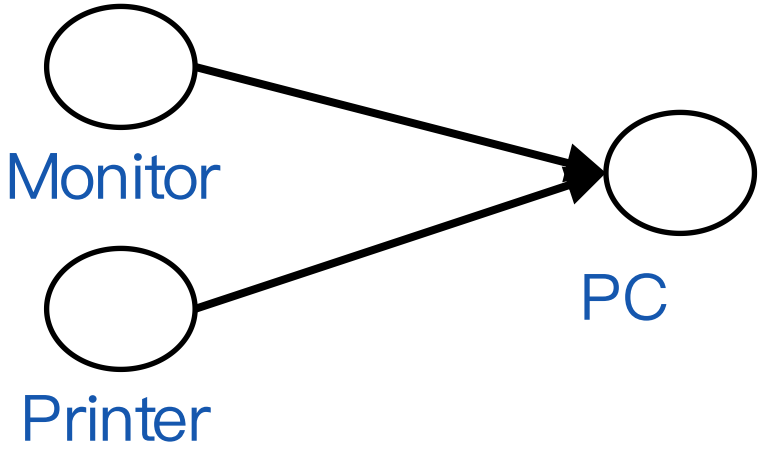

关联观测器 - C:\DOCUME~1\GONGZH~1\LOCALS~1\Temp\2V2AJ3Q3.C2T - 本地文件： ID■38186.xml

文件(F) 编辑(E) 选定项(S) 查看(V) 帮助(H)

规则 | 项目集合 | 图 | 统计信息

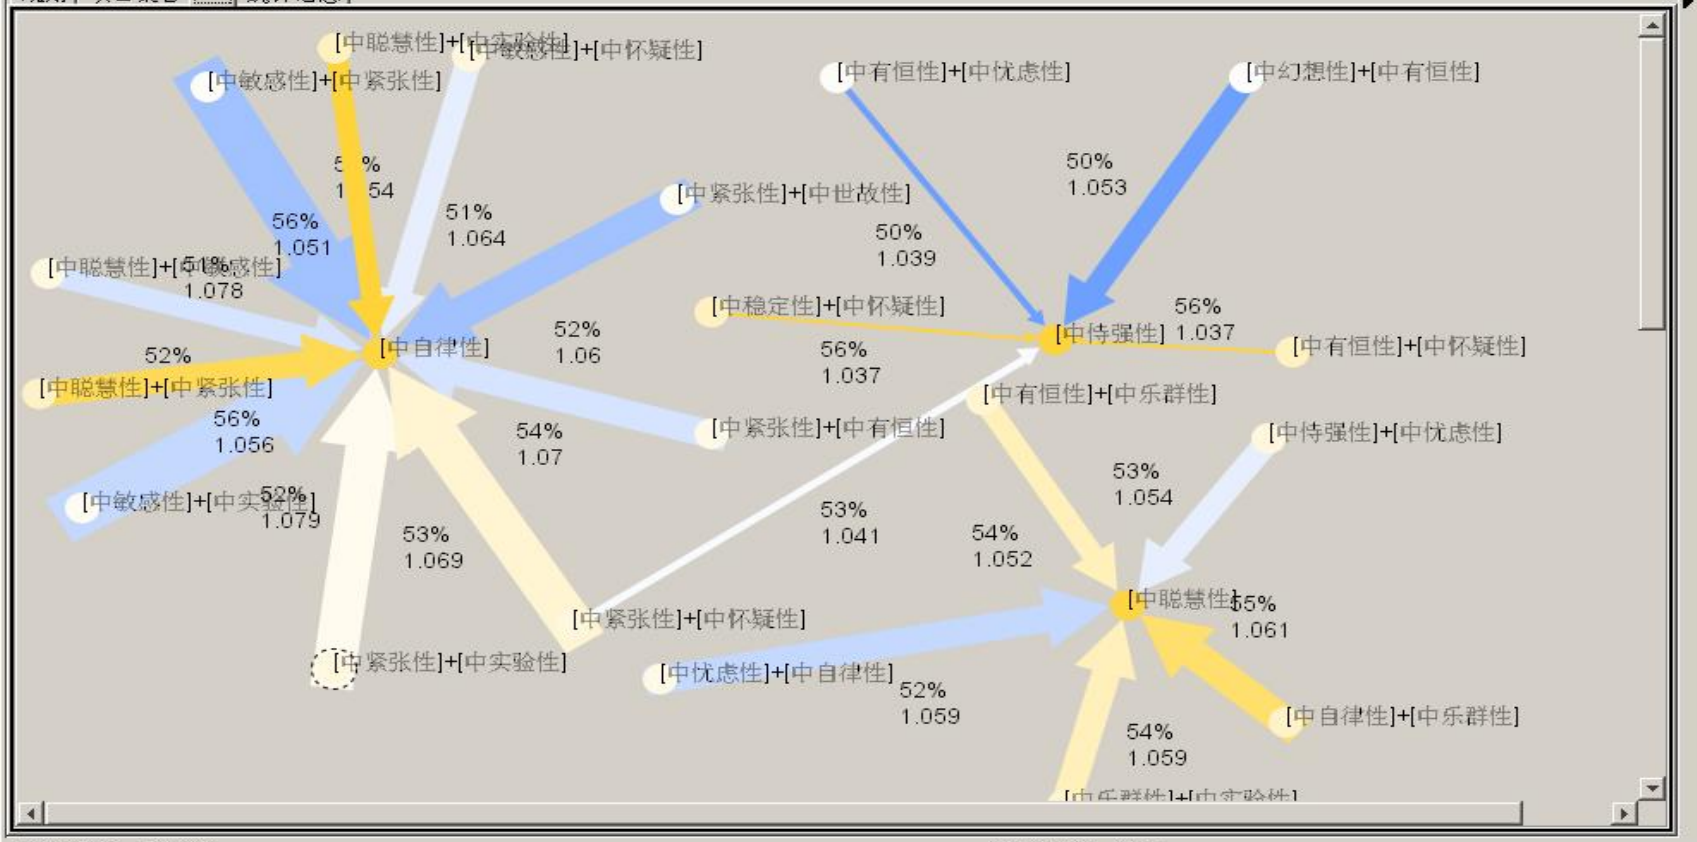


规则颜色：支持度

50.00% 50.63% 51.26% 51.89% 52.53% 53.16% 54.11% 55.06% 56.02%

规则宽度：提升

1.037 1.042 1.047 1.053 1.058 1.063 1.069 1.074 1.079

项目集合颜色：支持度

50.00% 53.44% 56.89% 60.16% 63.43% 66.71% 69.98% 73.26% 76.53% 79.81% 83.08%

模型中有 270 个项目集合和 20 个规则 | 只读

# 3.2 由事务数据库挖掘布尔关联规则

- 关联规则可视化
  - 3D可视化

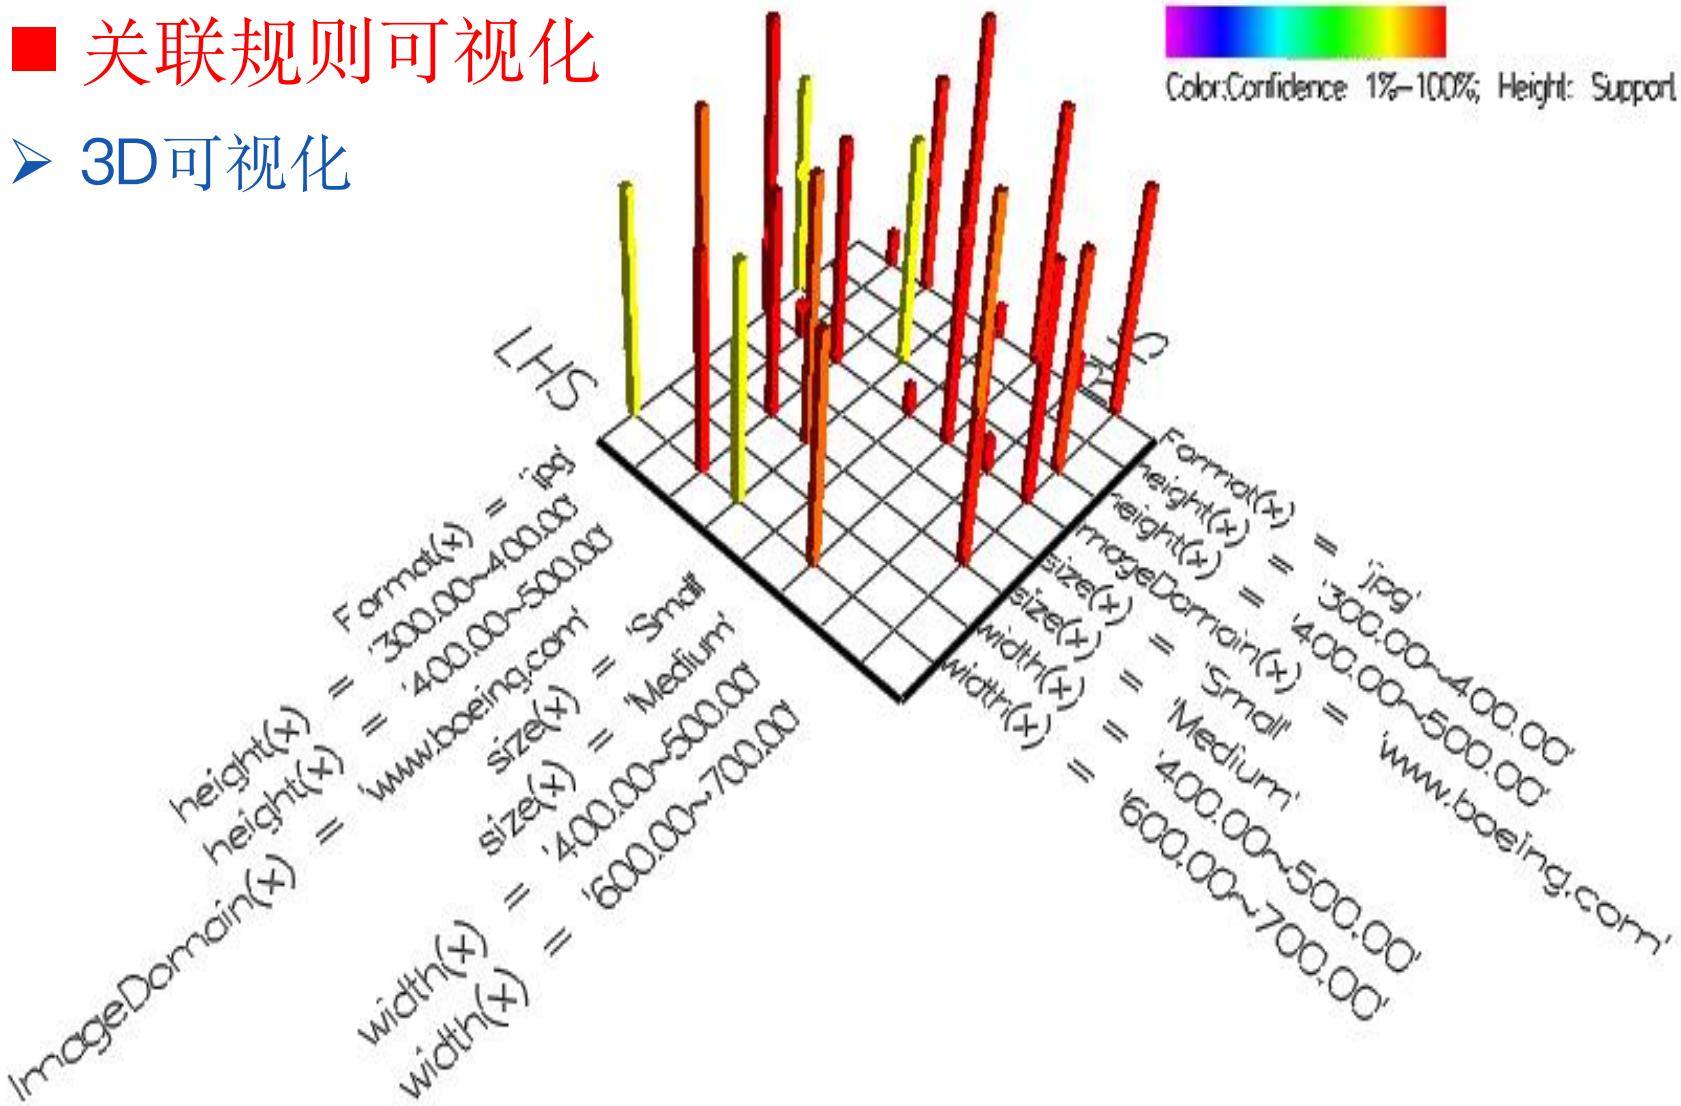

# 本章内容

3.1 关联规则挖掘的基本概念

3.2 由事务数据库挖掘单维布尔关联规则

3.3 多层关联规则挖掘

3.4 多维关联规则挖掘

3.5 关联规则、相关性、因果关系的区别

# 3.3 多层关联规则挖掘

- 数据项中经常会形成概念分层
- 底层数据项，其支持度往往也较低
  - 挖掘底层数据项之间的关联规则必须定义不同的支持度

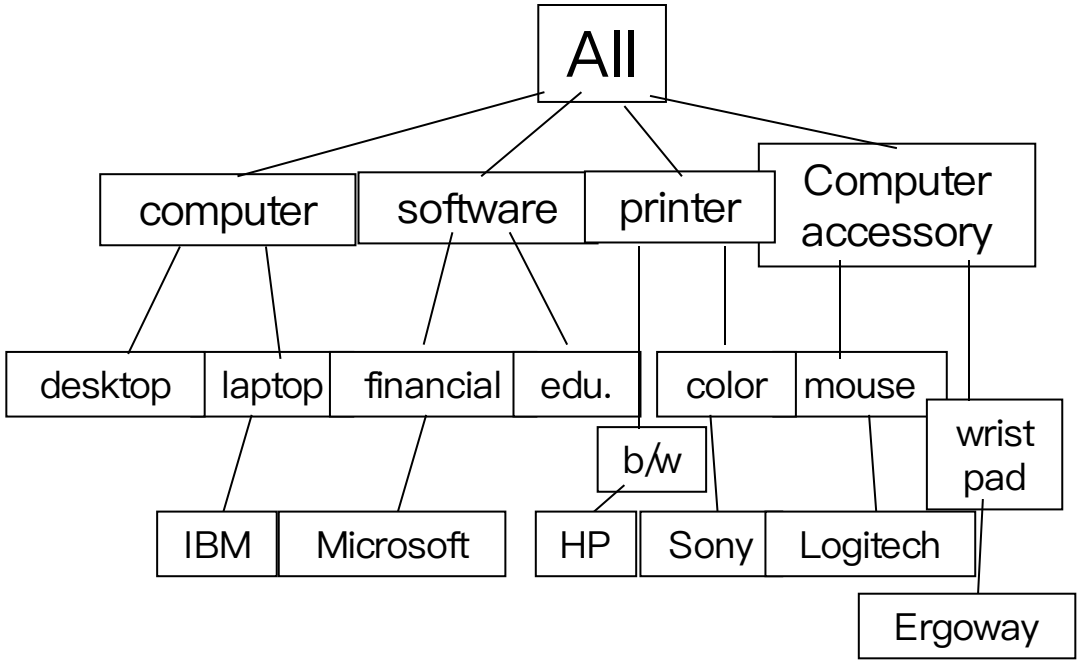


| TID | Items |
|---|---|
| T1 | {IBM D/C, Sony b/w} |
| T2 | {Ms. edu. Sw., Ms. fin. Sw.} |
| T3 | {Logi. mouse, Ergoway wrist pad} |
| T4 | {IBM D/C, Ms. Fin. Sw.} |
| T5 | {IBM D/C} |

# 3.3 多层关联规则挖掘

- 在适当的等级挖掘出来的数据项间的关联规则可能是非常有用的
- 事务数据库中的数据也是根据维和概念分层来进行储存的
  - 这为从事务数据库中挖掘不同层次的关联规则提供了可能。
- 在多个抽象层挖掘关联规则，并在不同的抽象层进行转化，是数据挖掘系统应该提供的能力

# 3.3 多层关联规则挖掘

- 多层关联规则的挖掘还是使用置信度－支持度框架，可以采用自顶向下策略
  - 概念分层中，一个节点的支持度肯定不小于该节点的任何子节点的支持度（为什么？）
  - 由概念层1开始向下，到较低的更特定的概念层，对每个概念层的频繁项计算累加计数
  - 每一层的关联规则挖掘可以使用Apriori等多种方法
  - 例如：
    - 先找高层的关联规则：computer -> printer [20%, 60%]
    - 再找较低层的关联规则：laptop -> color printer [10%, 50%]

# 3.3 多层关联规则挖掘

- 一致支持度：对所有层都使用一致的最小支持度
  - 优点：搜索时容易采用优化策略，即一个项如果不满足最小支持度，它的所有子项都可以不用搜索
  - 缺点：最小支持度值设置困难
    - 太高：将丢掉出现在较低抽象层中有意义的关联规则
    - 太低：会在较高层产生太多的无兴趣的规则

# 3.3 多层关联规则挖掘

- 使用递减支持度，可以解决使用一致支持度时在最小支持度值上设定的困难
- 递减支持度：在较低层使用递减的最小支持度
  - 每一层都有自己的一个独立的最小支持度
  - 抽象层越低，对应的最小支持度越小

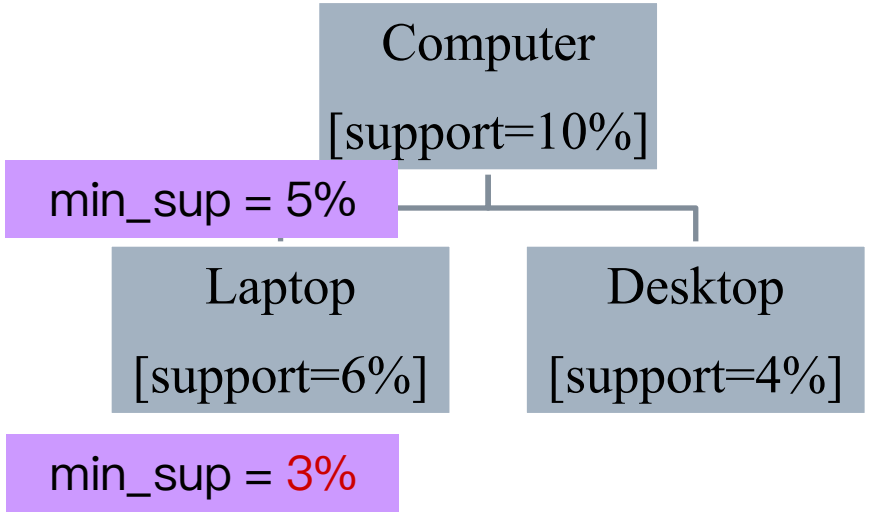

# 3.3 多层关联规则挖掘

## ■ 多层关联——基于分组的支持度

- 用户和专家清楚哪些分组比其他分组更加重要，在挖掘多层关联规则时，使用用户指定的基于项或者基于分组的最小支持度阈值
  - E.g. 对laptop_computer或者flash_drives设置特别低的支持度阈值，以便特别关注这类商品的管理模式

# 3.3 多层关联规则挖掘

Hierarchy-information encoded transaction table: T[1]

| TID | Items |
|---|---|
| $T_1$ | {111, 121, 211, 221} |
| $T_2$ | {111, 211, 222, 323} |
| $T_3$ | {112, 122, 221, 411} |
| $T_4$ | {111, 121} |
| $T_5$ | {111, 122, 211, 221, 413} |
| $T_6$ | {211, 323, 524} |
| $T_7$ | {323, 411, 524, 713} |

# 3.3 多层关联规则挖掘

**minsup[1] = 4**

**1**

**Level-1 large 1-itemsets: L[1, 1]**

| Itemset | Support |
|---|---|
| {1**} | 5 |
| {2**} | 5 |

**2**

**Filtered transaction table: T[2]**

| TID | Items |
|---|---|
| $T_1$ | {111, 121, 211, 221} |
| $T_2$ | {111, 211, 222} |
| $T_3$ | {112, 122, 221} |
| $T_4$ | {111, 121} |
| $T_5$ | {111, 122, 211, 221} |
| $T_6$ | {211} |

**3**

**Level-1 large 2-itemsets: L[1, 2]**

–Use L[1,1] and T[2]

L[1,1] is used to filter:

(1) any item which is not large in a transaction

(2) the transactions in T[1] which contain only small items

# 3.3 多层关联规则挖掘

**minsup[2] = 3**

Level-2 large 1-itemsets:
L[2, 1] (Note 1)

| Itemset | Support |
|---|---|
| {11*} | 5 |
| {12*} | 4 |
| {21*} | 4 |
| {22*} | 4 |

Level-2 large 2-itemsets:
L[2, 2] (Note 2)

| Itemset | Support |
|---|---|
| {11*, 12*} | 4 |
| {11*, 21*} | 3 |
| {11*, 22*} | 4 |
| {12*, 22*} | 3 |
| {21*, 22*} | 3 |

Level-2 large 3-itemsets:
L[2, 3] (Note 3)

| Itemset | Support |
|---|---|
| {11*, 12*, 22*} | 3 |
| {11*, 21*, 22*} | 3 |

| TID | Items |
|---|---|
| $T_1$ | {111, 121, 211, 221} |
| $T_2$ | {111, 211, 222} |
| $T_3$ | {112, 122, 221} |
| $T_4$ | {111, 121} |
| $T_5$ | {111, 122, 211, 221} |
| $T_6$ | {211} |

# 3.3 多层关联规则挖掘

**minsup[3] = 3**

Level-3 large 1-itemsets:
L[3, 1] (Note 1)

| Itemset | Support |
|---|---|
| {111} | 4 |
| {211} | 4 |
| {221} | 3 |

Level-3 large 2-itemsets:
L[3, 2]

| Itemset | Support |
|---|---|
| {111, 211} | 3 |

| TID | Items |
|---|---|
| $T_1$ | {111, 121, 211, 221} |
| $T_2$ | {111, 211, 222} |
| $T_3$ | {112, 122, 221} |
| $T_4$ | {111, 121} |
| $T_5$ | {111, 122, 211, 221} |
| $T_6$ | {211} |

# 本章内容

3.1 关联规则挖掘的基本概念

3.2 由事务数据库挖掘单维布尔关联规则

3.3 多层关联规则挖掘

3.4 多维关联规则挖掘

3.5 关联规则、相关性、因果关系的区别

# 3.4 多维关联规则挖掘

- 单维关联规则：
  - buys(X, “milk”) = buys(X, “bread”)
- 多维关联规则：涉及两个或多个维或谓词的关联规则
  - 维间关联规则：不包含重复的谓词
    - age(X,”19–25”) ∧ occupation(X,“student”) => buys(X,“coke”)
  - 混合维关联规则：包含某些谓词的多次出现
    - age(X,”19–25”) ∧ buys(X, “popcorn”) => buys(X, “coke”)
- 在多维关联规则挖掘中，搜索的不是频繁项集，而是频繁谓词集。k-谓词集是包含k个合取谓词的集合。
  - 例如：{age, occupation, buys}是一个3-谓词集

# 3.4 多维关联规则挖掘

- 数据属性可以分为类别属性和数值属性
  - 类别属性: 具有有限个不同值，值之间无序
  - 数值属性: 数值类型，并且值之间有一个隐含的序
- 对量化属性的处理:
  - 1. 静态离散化：使用预定义的概念分层对数值属性进行静态地离散化
  - 2. 量化关联规则：根据数据的分布，将数值属性离散化到“箱”
  - 3. 基于距离的关联规则：考虑数据点之间的距离，动态地离散化量化

# 3.4 多维关联规则挖掘

| RecordID | Age | Married | NumCars |
|---|---|---|---|
| 100 | 23 | No | 1 |
| 200 | 25 | Yes | 1 |
| 300 | 29 | No | 0 |
| 400 | 34 | Yes | 2 |
| 500 | 38 | Yes | 2 |

- <Age: 30..39> and <Married: Yes> => <NumCars: 2>
- Support = 40%, Conf = 100%

# 3.4 多维关联规则挖掘

- 基本思路：将数值型关联规则挖掘转化为布尔型关联规则挖掘
  - 引入<attribute: value> 作为新属性，这个属性是布尔型

| ID | Age: 20..29 | Age: 30..39 | Married: Yes | Married: No | NumCars: 0 | NumCars: 1 |
|---|---|---|---|---|---|---|
| 100 | 1 | 0 | 0 | 1 | 0 | 1 |
| 200 | 1 | 0 | 1 | 0 | 0 | 1 |
| 300 | 1 | 0 | 0 | 1 | 1 | 0 |
| 400 | 0 | 1 | 1 | 0 | 0 | 0 |
| 500 | 0 | 1 | 1 | 0 | 0 | 0 |

# 3.4 多维关联规则挖掘

- 聚焦于以下形式的2-维量化关联规则：
  - 两个量化属性和一个分类属性间的关联：

    $A_{quan1} \wedge A_{quan2} \Rightarrow A_{cat}$

  - 如： *age(X,"30-39") ∧ income(X,"42K –48K") ⇒ buys(X,"high resolution TV")*

- 关联规则聚类系统 (Association Rule Clustering System, ARCS)

✓ 源于图像处理技术，该技术将量化属性对映射到满足给定分类属性条件的2-D栅格上，然后通过搜索栅格点的聚类而产生关联规则

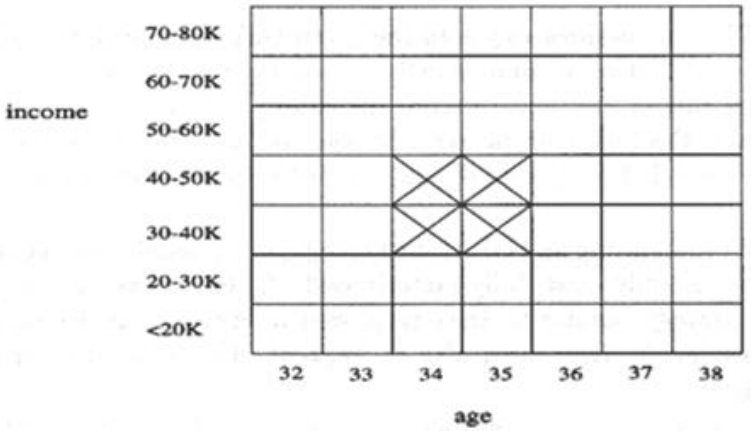

# 3.4 多维关联规则挖掘

■ ARCS过程:

1. Binning

2. Find frequent predicateset

3. Clustering

4. Optimize

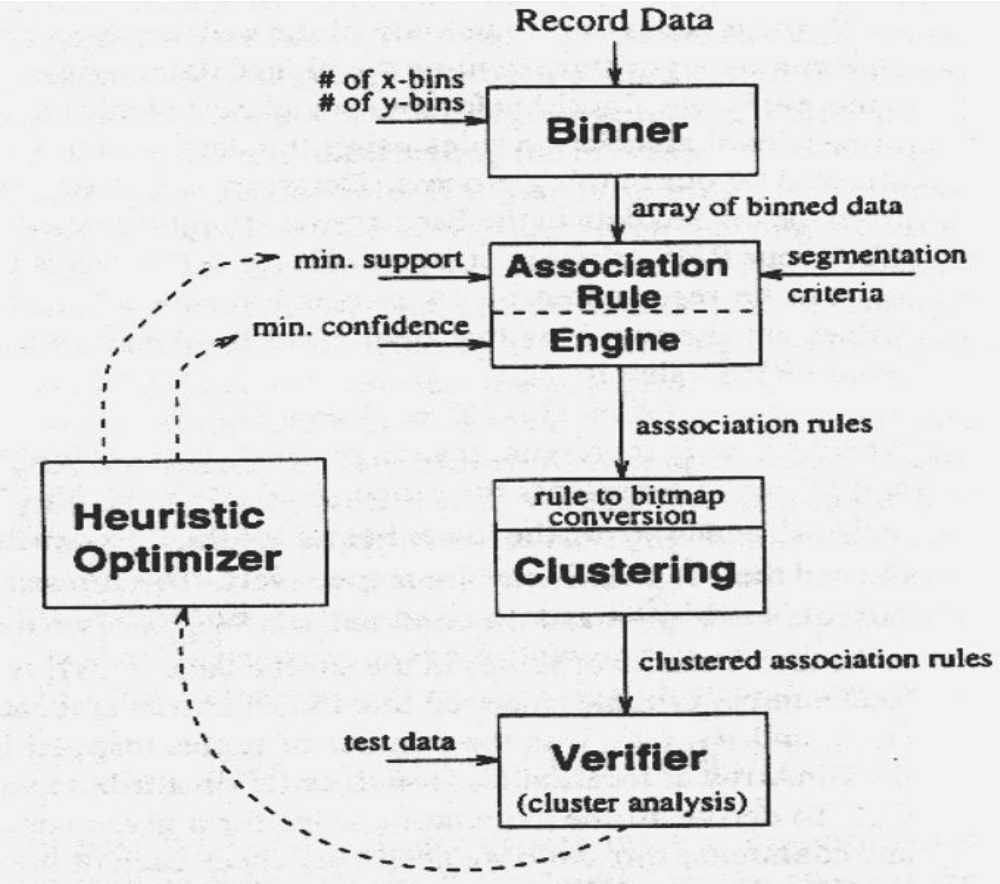

# 3.4 多维关联规则挖掘

## ■ ARCS过程:

1. 分箱（根据不同分箱方法创建一个2-D数组），目的在于减少量化属性相对应的巨大的值个数，使得2-D栅格的大小可控
   - 等宽分箱
   - 等深分箱
   - 基于同质的分箱（每个箱中元组一致分布）
2. 找出频繁谓词集
   - 扫描分箱后形成的2-D数组，找出满足最小支持度和置信度的频繁谓词集

# 3.4 多维关联规则挖掘

## ARCS过程:

3. 关联规则聚类

- 将上一步得到的强关联规则映射到2-D栅格上，使用聚类算法，扫描栅格，搜索规则的矩形聚类

$$age(X,35) \wedge income(X,"31K\ldots 40K") \Rightarrow buys(X,"high_resolution_TV")$$

$$age(X,34) \wedge income(X,"41K\ldots 50K") \Rightarrow buys(X,"high_resolution_TV")$$

$$age(X,35) \wedge income(X,"41K\ldots 50K") \Rightarrow buys(X,"high_resolution_TV")$$

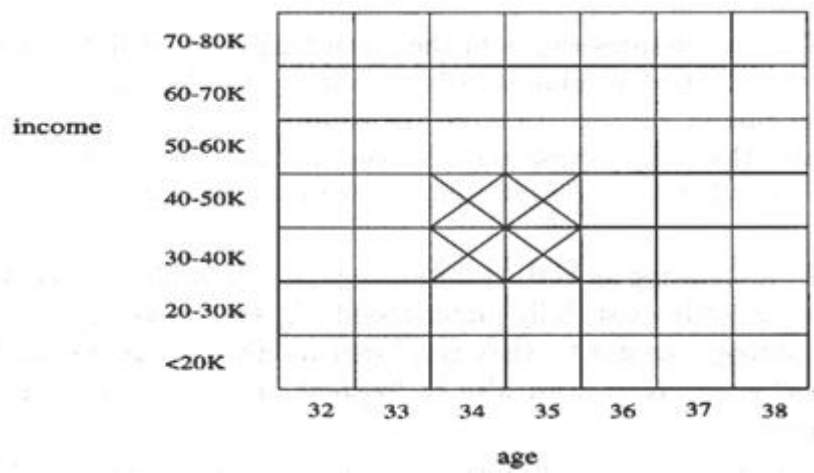


$$age(X,34\ldots 35) \wedge income(X,"31K\ldots 50K") \Rightarrow buys(X,"high_resolution_TV")$$

# 3.4 多维关联规则挖掘

- ARCS的局限性:
  - ✓ 规则的左手边只能有两个量化属性（2-D栅格的限制）

# 3.4 数值型关联规则挖掘

- *MinSup* 问题：如果数值型属性离散化后产生的区间的数量过多，单个区间的支持度就会较小，那么由于最小支持度限制，涉及这个属性的规则就可能不存在。区间数量增多也是布尔型属性增多，潜在规则会爆炸性增长
- *MinConf* 问题：当把数值型属性离散化为区间时，会产生信息丢失，当区间越大时，信息丢失的也就越多。
- *Catch-22* 两难境地：
  - 如果区间过大，一些规则由于最小置信度问题可能丢失
  - 如果区间过小，一些规则由于最小支持度问题可能丢失

# 本章内容

3.1 关联规则挖掘的基本概念

3.2 由事务数据库挖掘单维布尔关联规则

3.3 多层关联规则挖掘

3.4 多维关联规则挖掘

3.5 关联规则、相关性、因果关系的区别

# 3.5 关联规则、相关性、因果关系的区别

- 问题1： 强关联规则是否是正相关的?
- 问题2: 强关联规则是否存在因果关系?
- 问题3: 相关性是否意味着因果关系?
- 问题4: 如何定义因果关系?

# 3.5 关联规则、相关性、因果关系的区别

- 问题1：强关联规则是否是正相关的?
- 相关性：两个变量存在联系，一个变量会随着另一个变量变化，分为正相关和负相关

# 3.5 关联规则、相关性、因果关系的区别

| | 打篮球 | 不打篮球 | 合计 |
|---|---|---|---|
| 喝麦片 | 2000 | 1750 | 3750 |
| 不喝麦片 | 1000 | 250 | 1250 |
| 合计 | 3000 | 2000 | 5000 |

■ 例：(Aggarwal & Yu, PODS98)

- 在5000个学生中
  - 3000个打篮球
  - 3750个喝麦片粥
  - 2000个学生既打篮球又喝麦片粥
- 然而，打篮球 => 喝麦片粥 [？%, ？%]是无趣的，因为全部学生中喝麦片粥的比率是75%，比打篮球学生的66.7%要高
- 打篮球 => 不喝麦片粥 [20%, 33.3%]这个规则远比上面那个要精确，尽管支持度和置信度都要低的多

# 3.5 关联规则、相关性、因果关系的区别

- X and Y：正相关
- X and Z：负相关

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| X | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 0 |
| Y | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| Z | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |

| Rule | Support | Confidence |
|---|---|---|
| X=>Y | 25% | 50% |
| X=>Z | | |

强关联规则 ≠ 正相关!

陷阱：高置信度规则 A → B 可能具有误导性。

# 3.5 关联规则、相关性、因果关系的区别

## 关联规则与相关性

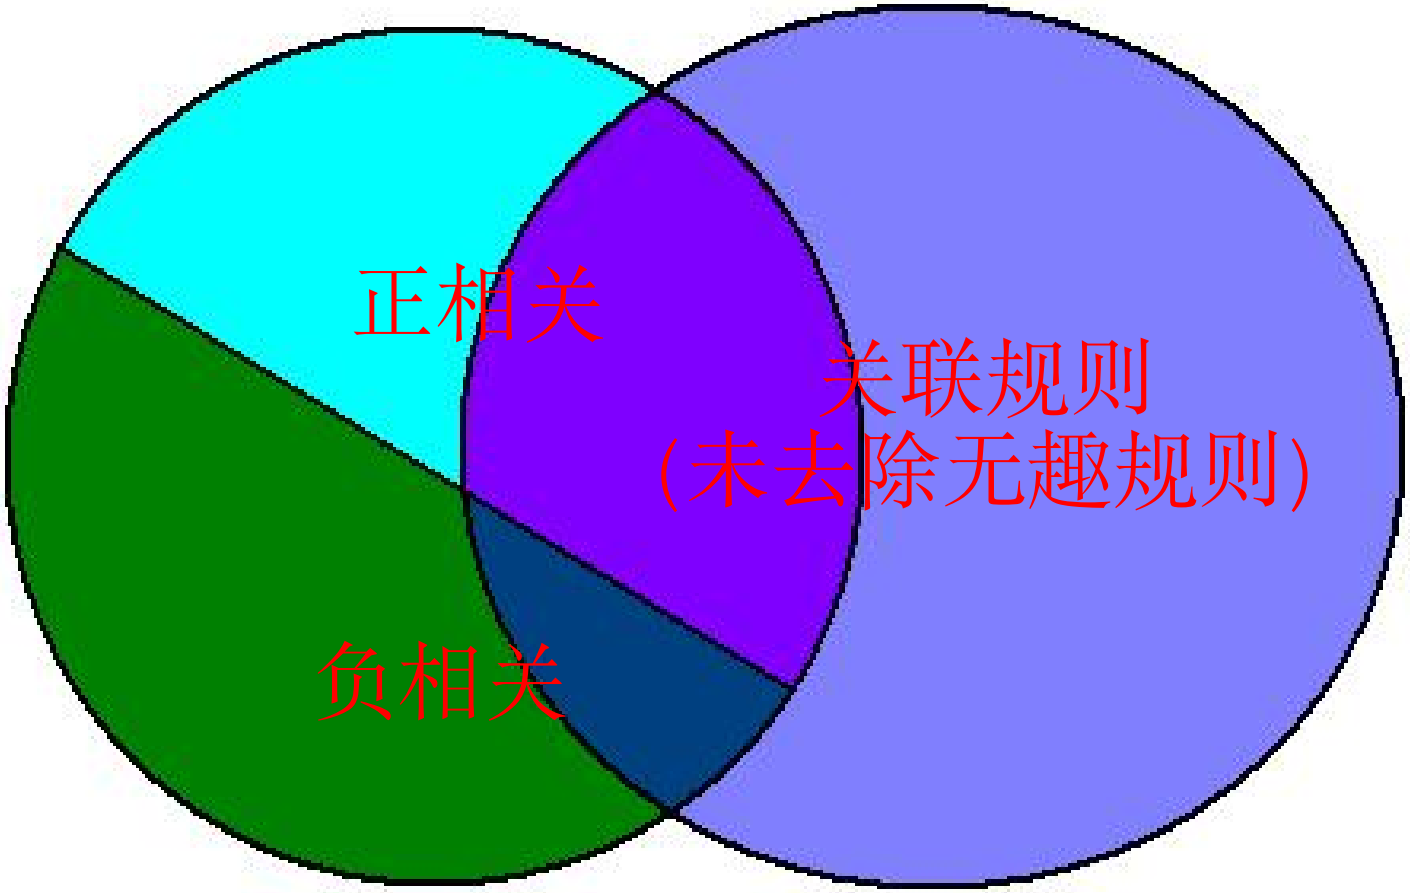

# 3.5 关联规则、相关性、因果关系的区别

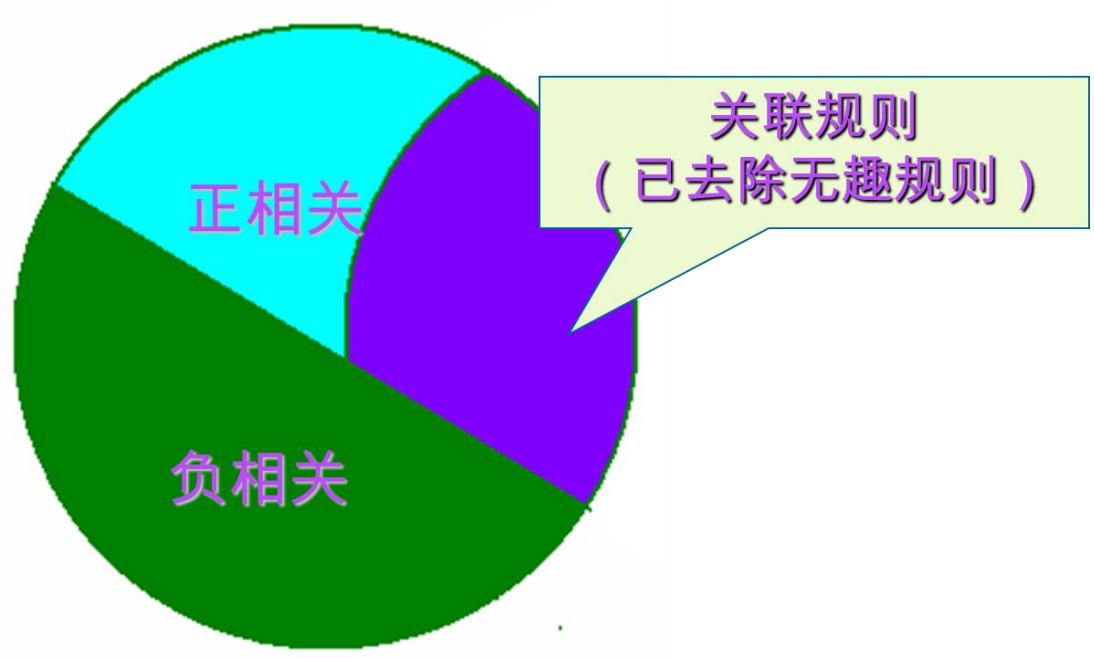


- 可使用相关度来扩充关联规则的支持度—置信度框架

$$A \Rightarrow B[\sup port, confidence, correlation]$$

- 需要一种度量事件间的相关性或者是依赖性的指标

# 3.5 关联规则、相关性、因果关系的区别

- 提升度指标 (lift)

$$A\text{和}B\text{间的提升度：}\ lift(A,B)=\frac{P(A\cup B)}{\mathrm{P(A)P(B)}}=P(B\mid A)/P(B)$$

- 当项集A的出现独立于项集B时，P(A∪B)=P(A)P(B)，即lift(A,B) = 1，表明A与B无关， lift(A,B) >1表明A与B正相关， lift(A,B) <1表明A与B负相关

# 3.5 关联规则、相关性、因果关系的区别

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| X | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 0 |
| Y | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| Z | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |

| Itemset | Support | lift |
|---|---|---|
| X,Y | 25% | 2 |
| X,Z | 37.50% | 0.9 |
| Y,Z | 12.50% | 0.57 |

# 3.5 关联规则、相关性、因果关系的区别

- 问题2：强关联规则是否存在因果关系？
- 因果关系：变量或事件之间的直接作用关系

周一上DM课 => 太阳东方升起 [1/7, 100%]

强关联规则 ≠ 因果关系！

# 3.5 关联规则、相关性、因果关系的区别

■ 相关性有助于为发现因果关系提供线索

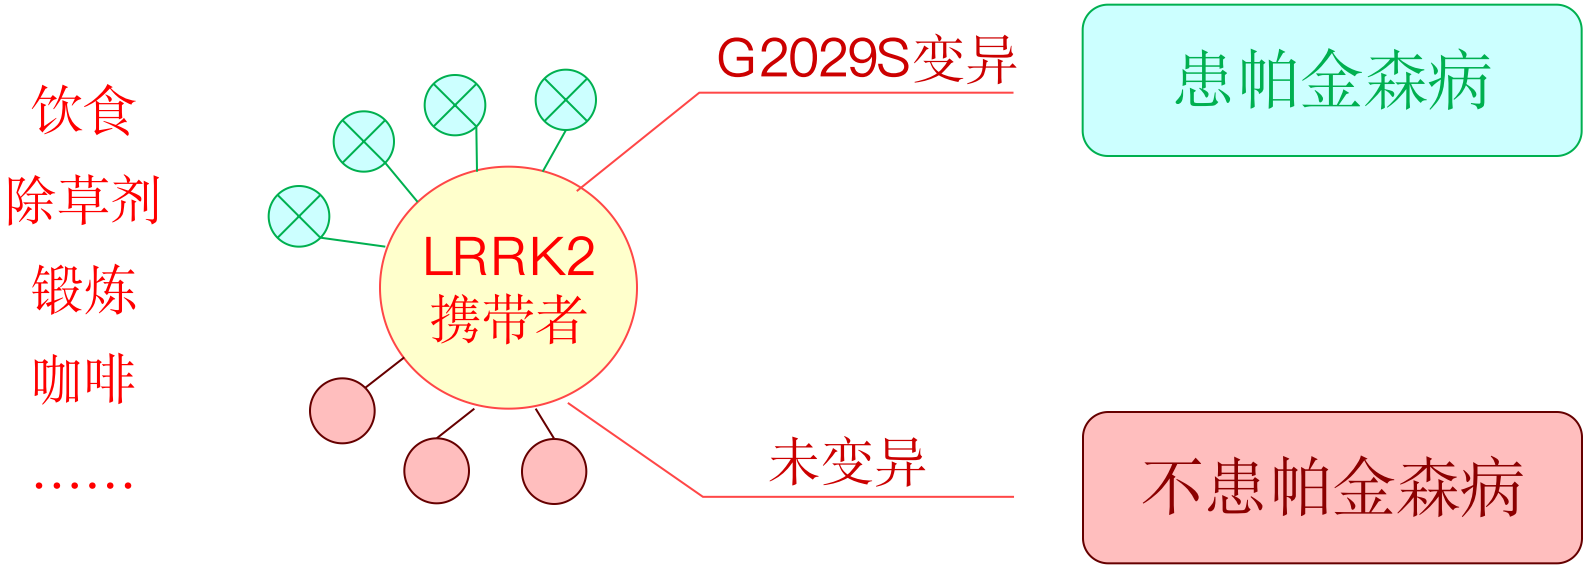


LRRK2携带者患帕金森的几率达到 30%–75%，普通患症的几率只有1%

# 3.5 关联规则、相关性、因果关系的区别

- 问题4：如何定义因果关系？
- Granger因果关系：若在包含了变量X、Y的过去信息的条件下，对变量Y的预测效果要优于只单独由Y的过去信息对Y的预测效果，即变量X 、Y有因果关系，变量X是变量Y的Granger原因

Clive W.J.Granger
诺贝尔经济学奖获奖者

# 总结

- Association rule mining consists of first finding frequent itemsets, from which strong association are generated. Associations can be further analyzed to uncover correlation rules, which convey statistical correlations between itemsets A and B.
- The Apriori algorithm is a seminal algorithm for mining frequent item sets for Boolean association rules.
- Mining frequent itemsets and associations has been extended in various ways to include mining multilevel association rules and multidimensional association rules.
- Not all strong association rules are interesting.