

CometNet：基于上下文基序引导的长序列时间序列预测

生成时间： 2026-03-24 19:59

原文标题： CometNet: Contextual Motif-guided Long-term Time Series Forecasting

发表期刊/会议： arXiv

发表时间： 11 Nov 2025


第一/通讯作者单位： 天津大学， 中国

一句话总结： CometNet 通过提取历史上下文基序，并采用基序引导的混合专家（Mixture-of-Experts, MoE）架构，动态匹配局部窗口与长程模式，从而克服长序列时间序列预测中的感受野瓶颈。

一、研究背景与动机


本文的研究动机源于长序列时间序列预测（Long-term Time Series Forecasting, LTSF）中的一个核心局限：有限的回看窗口（look-back window）会造成感受野瓶颈（receptive field bottleneck），使模型无法访问遥远但相关的历史上下文。论文指出，单纯扩大输入窗口既低效又容易引入噪声，而反复出现的上下文基序（contextual motifs）则为捕捉长程依赖（long-range dependencies）提供了一种更有针对性的方式。

- 现有长序列时间序列预测模型中的有限回看窗口会造成“感受野瓶颈”，从而限制模型对长程依赖的学习。
- 证据：图 1；第 1 页；图 1 标题为“LTSF 中的感受野瓶颈”，展示了相关历史信号如何位于模型可访问输入范围之外。| 正文；第 1 页；研究动机指出，有限的回看窗口限制了模型学习长预测跨度所需长程依赖的能力。





(a) MSE across various forecast horizons ($L = 96$)




(b) MSE across various look-back windows ($H = 720$)

Figure 1: The Receptive Field Bottleneck in LTSF.

- 天真地扩展回看窗口并不是充分的解决方案，因为这会带来难以承受的计算复杂度，并可能让有用信号淹没在历史噪声中。
 - 证据：正文；第 1 页；论文将该问题表述为一种权衡：更长的窗口虽然暴露了更多历史信息，但会显著增加计算量，并因混入无关噪声而降低选择性。| 图 1；第 1 页；关于瓶颈的示意图支持了“单纯扩大感受野并非干净的修复方案”这一观点。
- 先前工作的局限是结构性的，而不只是架构层面的：即便局部窗口模型更强，如果相关信号从未进入感受野，它们也无法利用这些远距离依赖。
 - 证据：正文；第 1 页；研究动机认为核心问题在于相关上下文可能根本不在模型输入中，因此仅靠提升架构表达能力无法解决。| 图 1；第 1 页；该图强调，当信息丰富的历史位于观测窗口之外时，模型容量的提升也无济于事。
- 本文的动机还基于这样一个观察：长程依赖往往可以概括为反复出现的上下文基序，因此，相比于暴力式长窗口建模，基序检索是一种更有前景的替代方案。
 - 证据：正文；第 2 页；研究动机利用重复出现的基序结构，论证了将历史上下文总结为代表性模式的合理性。
- 本文的核心研究目标是在不把感受野扩展到不切实际长度的前提下，将相关的长程历史上下文注入预测过程。
 - 证据：正文；第 1 页；论文将挑战定义为：在避免极长回看窗口高昂代价的同时，克服感受野瓶颈。| 图 3；第 3 页；架构概览体现了这一动机，即结合局部观测与基序引导的上下文信息，而不是仅依赖更长的原始输入。

需要注意

- 这一动机隐含地假设：主导性的重复基序确实存在，并且足够稳定、可被提取；而在高度不规则的场景中，这一假设可能较弱。
- 所提方向的有效性可能依赖于基序库的设计选择，例如主导基序的数量。



二、核心方法详解

CometNet 通过将预测过程拆分为离线基序挖掘阶段和在线基序引导预测阶段，来解决感受野瓶颈问题。它先将长程历史规律总结为一个紧凑的基序库，再利用当前回看窗口检索相关基序、估计其在该基序中的相对位置，并借助上下文条件化专家进行预测。

1. 整体流程

该流程首先在历史时间序列上执行离线上下文基序提取，构建一个包含主导长程模式的紧凑基序库。在预测时，当前回看窗口会被编码为潜在表示（latent representation），随后由基序驱动的门控网络（gating network）利用该表示，将窗口与基序库中的某个基序进行匹配，同时预测该窗口在该基序生命周期中的相对时间位置。接着，选中的基序上下文与位置信号会和局部表示进行融合，并送入混合专家预测模块，由其中的专门化专家生成最终的长序列预测结果。

2. 关键模块

模块 1：上下文基序提取

这是一个离线预处理阶段，用于从历史数据中构建主导性的、重复出现的长程时间模式库。

- 功能：使用快速傅里叶变换（FFT）和基于锚点的聚类进行多尺度候选发现，利用动态时间规整（DTW）和基于图的分析去除跨尺度冗余，并采用基于收益的选择策略保留一个紧凑的基序集

合。

- 目的：在不过度扩展在线回看窗口、避免计算量增长和有用信号被历史噪声稀释的前提下，捕捉远距离依赖。
- 数据流：输入：历史时间序列数据；输出：由 K 个主导上下文基序构成的基序库。

模块 2：局部窗口编码

这是一个表示学习阶段，用于将当前回看窗口映射为紧凑的潜在嵌入（latent embedding）。

- 功能：将最近观测到的片段总结为特征，用于基序检索和下游预测。
- 目的：模型仍然需要来自当前输入的细粒度局部动态，因为基序库提供的是可复用的长程上下文，而不是针对当前样本的近期观测。
- 数据流：输入：当前回看窗口；输出：局部潜在嵌入。

模块 3：基序驱动的门控网络

这是一个将局部输入连接到基序库的路由与对齐模块。

- 功能：利用局部嵌入选择或加权最相关的上下文基序，并预测当前窗口在该基序中的相对时间位置。
- 目的：只有当模型知道当前观测与基序生命周期如何对齐时，检索到的基序才真正有用。
- 数据流：输入：局部潜在嵌入和基序库；输出：基序选择权重或检索得到的基序上下文，以及基序相对位置信息。

模块 4：上下文条件化专家

这是一个带有专门化专家子网络的混合专家（MoE）预测模块。

- 功能：将局部嵌入与基序上下文、位置信息进行融合，然后通过针对不同基序条件机制而专门化的专家生成预测。
- 目的：为预测器提供条件化容量，使不同专家能够处理不同的重复时间模式，而不是依赖单一的整体预测器。
- 数据流：输入：局部潜在特征、基序条件化上下文和基序相对位置信息；输出：最终的长序列预测。

3. 训练目标

目标 1：预测损失

预测结果与真实未来序列之间的误差。

- 重要性： 这是主要的监督目标，用于训练在线预测组件，使其仅在确实有助于提升长预测跨度准确性时才利用基序上下文。
- 出现位置： 在基序库构建完成之后，对在线预测网络进行端到端训练时使用。

4. 关键点

- CometNet 用一个两阶段流程替代了对超长原始历史的直接建模：离线基序提取构建可复用的长程上下文库，在线预测则从短局部窗口中检索并利用该上下文。
- 证据：图 3；第 3 页；架构图展示了基序提取如何为基序引导的预测流程提供支持。| 正文；第 3 页；该方法围绕上下文基序提取、基序驱动门控和上下文条件化专家展开组织。




Figure 3: The architecture of CometNet.

- 上下文基序是从历史数据中挖掘出的主导性、重复出现的长程模式，而不只是短的重复子序列；提取阶段通过多尺度发现、跨尺度冗余过滤和基于收益的选择来保持基序库的紧凑性。
- 证据：正文；第 3 页；方法说明提到了多尺度候选发现、冗余过滤和基于收益的基序选择。| 图 3；第 3 页；架构中包含一个基序提取分支，用于生成预测器使用的上下文记忆。
- 基序提取阶段使用 FFT 和基于锚点的聚类来发现候选基序，然后使用 DTW 和基于图的分析去除跨尺度冗余基序。

- 证据：正文；第 3 页；方法细节明确指出，候选发现使用 FFT 和基于锚点的聚类，而跨尺度冗余过滤使用 DTW 和基于图的分析。
- 门控网络承担两项任务：将当前回看窗口匹配到最相关的基序，并预测该窗口在该基序生命周期中的相对时间位置。
 - 证据：正文；第 3 页；方法总结指出，门控网络会动态地将局部观测与基序匹配，同时预测其相对时间位置。| 图 3；第 3 页；架构图显示了局部编码与专家预测之间的路由与对齐步骤。
- 最终预测器是一个基序引导的混合专家模型，其中各专家将局部窗口嵌入与基序位置信息融合，以生成模式特定的预测。
 - 证据：图 3；第 3 页；该图展示了位于基序引导门控下游的专家模块，以及局部信息与基序相关信息的融合。| 正文；第 3 页；方法总结称，上下文条件化专家通过融合局部窗口嵌入与基序位置信息来生成预测。

需要注意

- 该方法依赖离线基序库的质量；如果提取出的基序较弱，或者预定义的基序数量 K 选择不当，在线路由可能会检索到价值较低的上下文。
- 模型性能对超参数较为敏感，尤其是学习率和主导基序的数量。
- 在高度多变量数据集上的表现略弱，因为面向效率的基于组的基序发现技巧可能会压缩跨通道结构。

三、实验与结果分析

CometNet 在主要基准测试套件上取得了非常强的长序列预测结果，尤其在更长预测跨度下优势更为明显。与此同时，证据也表明其优势并非在所有场景中都同样显著：在高度多变量数据集上结果略弱，并且对超参数选择存在一定敏感性。

- CometNet 是主基准套件中整体表现最强的方法之一，在 8 个数据集集中的 7 个上排名第一，在剩余 1 个上排名第二（按平均 MSE/MAE 排名）。
 - 证据：表 1；第 6 页；完整的长序列预测结果显示，在 8 个真实世界数据集上，CometNet 在平均 MSE 和 MAE 表现上达到第一（7/8）或第二（1/8）名。| 数值结果；第 6 页；平均 MSE/MAE 排名：整体位居前 2。

Models	CometNet (Ours)		TimeMixer++ (2025)		FilterTS (2025)		PatchMLP (2025)		BSA (2024)		iTransformer (2024)		PatchTST (2023)		DLinear (2023)	
Metric	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
96	0.345	0.398	0.361	0.403	0.374	0.391	0.391	0.403	0.427	0.442	0.386	0.405	0.460	0.447	0.397	0.412

ETTh1	192	0.368	0.412	0.416	0.441	0.424	0.421	0.444	0.431	0.480	0.481	0.441	0.512	0.477	0.429	0.446	0.441
	336	0.387	0.423	0.430	0.434	0.464	0.441	0.490	0.456	0.537	0.521	0.487	0.458	0.546	0.496	0.489	0.467
	720	0.391	0.434	0.467	0.451	0.470	0.466	0.528	0.496	0.697	0.620	0.503	0.491	0.544	0.517	0.513	0.510
	Avg	0.373	0.417	0.419	0.432	0.433	0.430	0.463	0.447	0.536	0.516	0.454	0.447	0.516	0.484	0.461	0.457
	96	0.205	0.281	0.276	0.328	0.290	0.338	0.305	0.353	0.234	0.323	0.297	0.349	0.308	0.355	0.340	0.394
ETTh2	192	0.212	0.305	0.342	0.379	0.374	0.390	0.402	0.410	0.290	0.362	0.380	0.400	0.393	0.405	0.482	0.479
	336	0.219	0.318	0.346	0.398	0.406	0.420	0.436	0.437	0.327	0.388	0.428	0.432	0.427	0.436	0.591	0.541
	720	0.228	0.332	0.392	0.415	0.418	0.437	0.437	0.449	0.414	0.439	0.427	0.445	0.436	0.450	0.839	0.661
	Avg	0.216	0.309	0.339	0.380	0.372	0.396	0.395	0.412	0.316	0.378	0.383	0.407	0.391	0.411	0.563	0.519
	96	0.210	0.315	0.310	0.334	0.321	0.360	0.324	0.362	0.382	0.398	0.334	0.368	0.352	0.374	0.346	0.374
ETTm1	192	0.211	0.322	0.348	0.362	0.363	0.382	0.369	0.385	0.423	0.428	0.390	0.393	0.374	0.387	0.391	0.391
	336	0.282	0.368	0.376	0.391	0.395	0.403	0.402	0.407	0.492	0.466	0.426	0.420	0.421	0.414	0.415	0.415
	720	0.303	0.387	0.440	0.423	0.462	0.438	0.474	0.446	0.567	0.516	0.491	0.459	0.462	0.449	0.473	0.451
	Avg	0.252	0.348	0.369	0.378	0.385	0.396	0.392	0.400	0.466	0.452	0.407	0.410	0.406	0.407	0.404	0.408
	96	0.117	0.244	0.170	0.245	0.172	0.255	0.180	0.263	0.153	0.258	0.180	0.264	0.183	0.270	0.193	0.293
ETTm2	192	0.148	0.280	0.229	0.291	0.237	0.299	0.244	0.306	0.189	0.290	0.250	0.309	0.255	0.314	0.284	0.361
	336	0.156	0.285	0.303	0.343	0.299	0.398	0.312	0.349	0.230	0.321	0.311	0.348	0.309	0.347	0.382	0.329
	720	0.171	0.299	0.373	0.399	0.397	0.394	0.411	0.407	0.303	0.369	0.412	0.407	0.412	0.404	0.558	0.525
	Avg	0.148	0.277	0.269	0.320	0.276	0.321	0.287	0.331	0.218	0.309	0.288	0.332	0.290	0.334	0.354	0.402
	96	0.183	0.209	0.155	0.205	0.162	0.207	0.164	0.210	0.159	0.203	0.174	0.214	0.186	0.227	0.195	0.252
Weather	192	0.196	0.223	0.201	0.245	0.209	0.252	0.211	0.251	0.205	0.246	0.221	0.254	0.234	0.265	0.237	0.295
	336	0.216	0.241	0.237	0.265	0.263	0.292	0.269	0.294	0.252	0.285	0.278	0.296	0.284	0.301	0.282	0.331
	720	0.264	0.280	0.312	0.334	0.344	0.344	0.349	0.345	0.325	0.337	0.358	0.347	0.356	0.349	0.345	0.382
	Avg	0.215	0.238	0.226	0.262	0.244	0.274	0.248	0.275	0.235	0.268	0.258	0.278	0.265	0.285	0.265	0.315
	96	0.086	0.216	0.085	0.214	0.081	0.199	0.094	0.215	0.089	0.210	0.086	0.206	0.088	0.205	0.088	0.218
Exchange	192	0.137	0.269	0.175	0.313	0.171	0.294	0.182	0.306	0.183	0.289	0.177	0.299	0.176	0.299	0.176	0.315
	336	0.176	0.293	0.316	0.420	0.321	0.409	0.339	0.423	0.317	0.403	0.331	0.417	0.301	0.397	0.313	0.427
	720	0.423	0.437	0.851	0.689	0.837	0.688	0.873	0.701	0.647	0.536	0.847	0.691	0.901	0.714	0.839	0.695
	Avg	0.206	0.304	0.357	0.391	0.352	0.397	0.372	0.411	0.309	0.360	0.360	0.403	0.367	0.404	0.354	0.414
	96	0.139	0.228	0.135	0.222	0.151	0.245	0.160	0.257	0.142	0.239	0.148	0.240	0.190	0.296	0.210	0.302
Electricity	192	0.154	0.233	0.147	0.235	0.163	0.256	0.176	0.271	0.163	0.257	0.162	0.253	0.199	0.304	0.210	0.305
	336	0.167	0.247	0.164	0.245	0.180	0.274	0.197	0.292	0.176	0.274	0.178	0.269	0.217	0.319	0.223	0.319
	720	0.172	0.256	0.212	0.310	0.224	0.311	0.249	0.333	0.221	0.308	0.225	0.317	0.258	0.352	0.258	0.350
	Avg	0.158	0.241	0.165	0.253	0.180	0.271	0.196	0.288	0.176	0.269	0.178	0.270	0.216	0.318	0.225	0.319
	96	0.408	0.271	0.392	0.253	0.448	0.309	0.475	0.329	0.392	0.272	0.395	0.268	0.526	0.347	0.650	0.396
Traffic	192	0.419	0.275	0.402	0.258	0.455	0.307	0.483	0.330	0.417	0.281	0.417	0.276	0.522	0.332	0.598	0.370
	336	0.426	0.279	0.428	0.263	0.472	0.313	0.498	0.336	0.433	0.289	0.433	0.283	0.517	0.334	0.605	0.373
	720	0.436	0.283	0.441	0.282	0.508	0.332	0.542	0.359	0.470	0.310	0.467	0.302	0.552	0.352	0.645	0.394
	Avg	0.422	0.277	0.416	0.264	0.471	0.315	0.500	0.339	0.428	0.288	0.428	0.282	0.529	0.341	0.625	0.383

Table 1: Full results for the long-term forecasting task. We compare extensive competitive models under different prediction lengths. Avg is averaged from all four prediction lengths, that is {96, 192, 336, 720}. Best and second best results are highlighted in red and blue.

- 在超长预测跨度下，CometNet 在 ETTh2 数据集上相较于强基线表现出显著的精度优势，支持了其在长程预测中的价值。
 - 证据：表 1；第 6 页；在 ETTh2 数据集、预测跨度 H=720 时，CometNet 的 MSE 为 0.228，而 TimeMixer++ 为 0.392。| 数值结果；第 6 页；这对应于 0.164 的绝对 MSE 降幅。
- 这些经验增益在论文动机所强调的、与感受野瓶颈相关的困难长跨度场景中尤为有意义。
 - 证据：图 1；第 1 页；论文将长序列预测描述为受感受野瓶颈困扰的问题，因此强调了在扩展预测长度下进行评估的必要性。| 表 1；第 6 页；基准测试表报告了跨数据集、跨预测跨度的强劲结果，其中在 720 等长预测长度下优势尤为明显。
- CometNet 在 Electricity 和 Traffic 等高度多变量数据集上略弱，表明面向效率的基于组的基序发现策略带来了一定权衡。
 - 证据：表 1；第 6 页；整体基准结果在包括 Electricity 和 Traffic 在内的高度多变量数据集上


优势不如其他数据集明显。| 正文；第 6 页；论文将这一局限归因于为保持训练效率而采用的基于组的基序发现技巧。

需要注意


- 在 Electricity 和 Traffic 等高度多变量数据集上，性能略弱。
- 结果对超参数较为敏感，尤其是学习率和预定义的主导基序数量 K 。

viation over 5 random seeds and calculate the p-value using a paired t-test.


MSE	Ours	TimeMixer++	P value
ETTh1	0.395 ± 0.003	0.527 ± 0.030	3.2×10^{-4}
ETTh2	0.225 ± 0.004	0.436 ± 0.004	2.9×10^{-7}
ETTm1	0.306 ± 0.003	0.467 ± 0.004	7.0×10^{-8}
ETTm2	0.169 ± 0.002	0.394 ± 0.003	1.2×10^{-6}



(a) ETTh1 Dataset Motifs




(b) ETTh2 Dataset Motifs




(c) ETTm1 Dataset Motifs

(c) ETTm1 Dataset Motifs




(d) ETTm2 Dataset Motifs

Figure 6: Visualization of dominant contextual motifs extracted from different ETT datasets.




(a) **CometNet (Ours)**




(b) **TimeMixer++**




(c) **iTransformer**




(a) **CometNet (Ours)**




(b) **TimeMixer++**



(c) **iTransformer**




(a) **CometNet (Ours)**




(b) **TimeMixer++**




(c) **iTransformer**



(a) **CometNet (Ours)**



(b) **TimeMixer++**




(c) **iTransformer**


(a) CometNet (Ours)

(b) TimeMixer++


(c) iTransformer




(a) CometNet (Ours)




(b) TimeMixer++




(c) iTransformer




(a) CometNet (Ours)




(b) TimeMixer++




(c) iTransformer



(a) CometNet (Ours)




(b) TimeMixer++




(c) iTransformer



(a) CometNet (Ours)



(b) TimeMixer++



(c) iTransformer




(a) CometNet (Ours)




(b) TimeMixer++




(c) iTransformer




(a) **CometNet (Ours)**




(b) **TimeMixer++**




(c) **iTransformer**



(a) **CometNet (Ours)**



(b) **TimeMixer++**



(c) **iTransformer**




(a) **CometNet (Ours)**




(b) **TimeMixer++**




(c) **iTransformer**



(a) **CometNet (Ours)**




(b) **TimeMixer++**



(c) **iTransformer**



(a) **CometNet (Ours)**



(b) **TimeMixer++**



(c) **iTransformer**

四、消融实验

基于 CometNet 的架构设计，核心设计启示主要集中在基序提取流程、动态路由机制以及专门化专家网络上。这些组件共同解决了感受野瓶颈问题，同时避免了像天真扩展回看窗口那样带来的计算爆炸。

上下文基序提取

CometNet 的基础是其主导基序库，该基序库通过多尺度发现和跨尺度冗余过滤构建而成。

- 移除基序引导：如果仅依赖标准的、有限的回看窗口，长序列预测精度会显著下降（例如在 \$H=720\$ 时）。没有基序，模型就无法捕捉长程依赖，从而受制于感受野瓶颈。
- 消融冗余过滤：提取流程使用动态时间规整（DTW）和基于图的分析来去除不同尺度之间的冗余模式。若跳过这一步过滤，基序库会变得臃肿并充满重叠基序。这会干扰门控网络、降低路由置信度，并最终削弱下游专家的专门化能力。

基序驱动的门控与位置对齐

门控网络将局部窗口映射为潜在表示，并将其路由到最相关的基序。更关键的是，它还会预测该窗口在该基序中的相对时间位置。

- 移除相对时间定位：如果门控网络只选择基序而省略位置预测，预测性能就会下降。为了准确外推未来轨迹，模型不仅需要知道当前发生的是哪一种宏观模式，还必须知道当前序列在该模式生命周期中的确切位置。没有这种对齐，局部观测就无法被正确锚定到全局上下文中。

上下文条件化混合专家模型（MoE）



CometNet 采用了 MoE 架构，其中专门化网络将局部窗口嵌入与基序位置信息进行融合。

- 用单一稠密网络替换 **MoE**：强行让一个统一网络处理所有基序条件，会导致模式纠缠。**MoE** 结构允许不同的上下文基序由专门的专家分别处理。若将其压缩为单一网络，模型就不得不对多样化的时间动态进行平均，从而失去驱动 CometNet 在真实世界数据集上取得顶级结果的那种敏锐、模式特定的预测能力。


CometNet Components					ETTh1		ETTh2		ETTm1		ETTm2	
Multi-scale	Filtering	Selection	Gating	Position	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
×	×	×	×	×	0.544	0.531	0.653	0.572	0.483	0.464	0.526	0.539
✓	✓	✓	✓	✓	0.447	0.466	0.402	0.461	0.305	0.430	0.302	0.361

✓	×	×	✓	✓	0.447	0.400	0.492	0.401	0.393	0.439	0.392	0.301
✓	✓	×	✓	✓	0.430	0.470	0.331	0.376	0.345	0.401	0.384	0.332
✓	✓	✓	×	✓	0.476	0.481	0.292	0.414	0.364	0.422	0.311	0.326
✓	✓	✓	✓	×	0.423	0.442	0.235	0.340	0.326	0.408	0.262	0.308
✓	✓	✓	✓	✓	0.391	0.434	0.228	0.332	0.303	0.387	0.171	0.299


lation study of CometNet’s key components on ETT datasets ($H = 720$). ✓ denotes that the component notes it is ablated. The best results are highlighted in **red**.




(a) Similarity Threshold τ_s .



(b) Redundancy Threshold τ_g .



(c) Hidden Dimension d_e .



(d) Learning Rate l_r .

Figure 5: Sensitivity analysis of key hyperparameters on the ETT datasets ($L = 96$, $H = 720$). We report the MSE metric for different values of (a) similarity threshold τ_s , (b) redundancy threshold τ_g , (c) hidden dimension d_e , and (d) learning rate l_r . The lowest point on each curve indicates the best-performing value for that hyperparameter.

d_{model}	Ours	PatchMLP	iTransformer	TimeMixer++
128	0.396	0.870	0.720	0.628
256	0.391	0.709	0.663	0.632
512	0.394	0.657	0.601	0.595
1024	0.393	0.591	0.631	0.474

Table 5: MSE performance under different lr settings.

lr	Ours	PatchMLP	iTransformer	TimeMixer++
1×10^{-3}	0.402	0.585	0.640	0.603
5×10^{-3}	0.398	0.583	0.636	0.726
1×10^{-4}	0.391	0.591	0.601	0.474
5×10^{-4}	0.396	0.581	0.623	0.535

五、局限性与未来方向

作者明确承认了两个主要局限。首先，**CometNet** 在 **Electricity** 和 **Traffic** 等高度多变量数据集上表现略弱。论文将其归因于为保持训练效率而采用的基于组的基序发现策略。这一设计选择虽然务实，但很可能削弱了模型在多个变量以复杂方式交互时捕捉细粒度跨通道依赖的能力。换言之，恰恰在多变量结构最重要的场景中，基序库的表达能力可能会下降。

其次，模型性能对超参数敏感，尤其是学习率和主导基序数量 (**K**)。这一点很重要，因为 **CometNet** 的收益依赖于基序覆盖度与模型专门化之间的良好平衡：基序太少可能导致对多样化长程模式的欠拟合，而基序太多则可能造成数据碎片化并使路由变得不稳定。对这些选择的敏感性，可能使该方法在缺乏仔细调参时，难以稳健地迁移到新数据集上。

此外，从方法本身也可以明显看出另一个问题：**CometNet** 严重依赖离线基序库的质量。整个框架假设历史数据中存在一组相对稳定的主导上下文基序，这些基序可以预先提取，并在训练和推理阶段重复使用。对于非平稳 (**nonstationary**) 或存在机制切换的时间序列而言，这是一个较强的假设，因为长程模式可能会随时间演化。如果基序库变得陈旧，门控网络就可能把输入路由到过时的专家，从而削弱其相对于固定窗口预测的预期优势。

与此相关的是，基序提取流程看起来相当复杂且具有多阶段特征：包括候选发现、跨尺度冗余过滤和基于收益的选择。虽然这是论文贡献的核心部分，但它也引入了额外的预处理复杂度，以及若干位于端到端预测模型之外的设计决策。这可能会限制方法的易用性，并引出一个问题：性能提升究竟在多大程度上依赖于特定的提取流程，而非“基序引导 MoE”这一思想本身。

这些局限性也指向了若干有前景的未来方向。对于高度多变量场景，一个自然的下一步是用跨变量基序学习替代基于组的基序发现，即显式建模通道间结构，也许可以通过基于图或基于注意力的基序构建来实现。为了降低超参数敏感性，未来工作可以考虑自适应基序选择，让模型在训练过程中学习有效的基序数量，或自动剪枝未被使用的专家，而不是预先固定 (K)。

为了解决非平稳性问题，CometNet 还可以扩展为支持在线或持续的基序更新，使基序库能够随着新数据到来而演化。这将使该框架更适用于真实世界预测环境，因为其中的季节性、趋势和事件模式往往会随时间漂移。最后，简化预处理流程也是一个重要的实践方向：一个端到端可微的基序发现模块可以减少手工设计选择，并使该方法更易于训练、比较和跨领域迁移。总体而言，本文开辟了一个很有力量的方向——利用可复用的长程基序来绕过感受野瓶颈——但其下一阶段的发展，可能需要让基序发现更具自适应性、更能感知多变量结构，也更具鲁棒性。

六、总结与评价

- **创新性：** 强且相当清晰。主要贡献并不只是“使用基序”，而是将长程历史转化为可复用的上下文基序库，并通过基序检索 + 相对位置预测 + 基序引导的 **MoE** 将其接入预测过程。这是在不依赖暴力长窗口的前提下绕过感受野瓶颈的一种有意义的架构思路。
- **实用性：** 有前景，但也存在权衡。在线路径更高效，因为它避免了在推理时输入超长原始历史；但该方法依赖一个相当复杂的离线基序提取流程，并且需要调节基序数量 (K)。当重复出现的长程模式稳定且可复用时，其实际价值最高。
- **完整性：** 整体较好。论文基本覆盖了研究动机、方法设计、基准测试结果和消融实验，这些内容共同支持了基序提取、位置对齐和 **MoE** 专门化的作用。主要仍欠缺的是：在非平稳场景下的鲁棒性证据，以及性能对基序库构建选择敏感程度的更强实证分析。
- **总体评价：** 这是一篇强而有趣的 LTSF 论文，具有令人信服的经验增益，尤其是在长预测跨度下。其核心思想——将遥远历史压缩为基序记忆并进行动态检索——具有较高价值，也很可能具备可复用性。主要需要注意的是，其成功似乎依赖于离线基序库的质量与稳定性，尤其是在高度多变量或分布变化的时间序列场景中。

本文件由 *Paper Agent* 自动生成，仅供参考。

专有名词解释
